PPgTI - UFRN

Reinforcement Learning em Aplicações Financeiras

Uma revisão crítica de métodos, resultados e desafios

REFERÊNCIA ACADÊMICA

“A Review of Reinforcement Learning in Financial Applications”

Autores: Yahui Bai, Yuhe Gao, Runzhe Wan, Sheng Zhang, Rui Song (2025)

Annual Review of Statistics and Its Application, vol. 12, pp. 209–232

Aprendizado por Reforço

Apresentado por: **Rafael Soares**

MOTIVAÇÃO & ESCOPO DO SURVEY

Por que Aprendizado por Reforço em Finanças?

Previsão de Preços (Supervisionado)

Foco estático: Minimiza erro de previsão ponto a ponto sem considerar fricção, impacto de ordens ou custos operacionais.

Tomada Sequencial de Decisão (RL)

Foco dinâmico: Aprende políticas $\pi(a|s)$ otimizando retorno acumulado e gerindo riscos ao longo do tempo.

CONTRIBUIÇÃO 1

Taxonomia Unificada

Mapeamento de MDPs em Market Making, Portfolio e Optimal Execution.

CONTRIBUIÇÃO 2

Meta-Análise Quantitativa

Avaliação via métrica original *RL Premium* sobre a literatura.

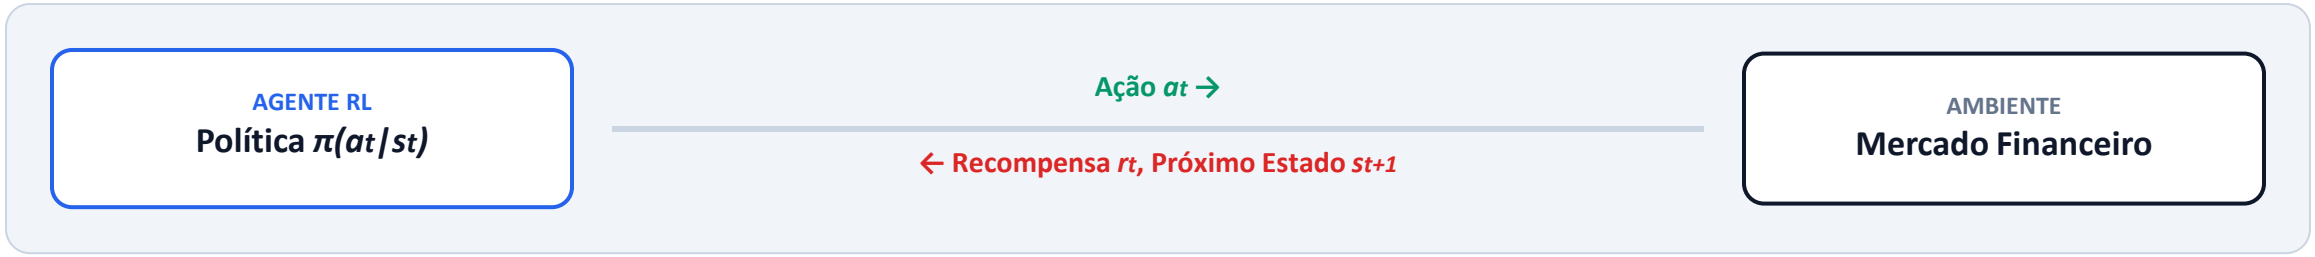
CONTRIBUIÇÃO 3

Diagnóstico de Desafios

Análise de não-estacionariedade, validação e diretrizes futuras.

FUNDAMENTAÇÃO TEÓRICA

Como Modelar Decisões Financeiras como MDPs?



ESTADO (S_T)

- **Preços & Retornos:** Histórico e volatilidade.
- **Inventário:** Posição atual de ativos.
- **Mercado:** Order book, spread bid-ask.
- **Sinais:** Indicadores técnicos e macro.

AÇÃO (A_T)

- **Execução:** Comprar, vender ou manter.
- **Alocação:** Pesos contínuos do portfólio.
- **Cotagem:** Preços e tamanhos bid/ask.
- **Volume:** Quantidade fracionada por etapa.

RECOMPENSA (R_T)

- **Lucro Direto:** PnL acumulado.
- **Ajustado ao Risco:** Sharpe / Sortino.
- **Penalidades:** Risco de inventário e custos.
- **Execução:** Implementation Shortfall.

DOMÍNIOS DE APLICAÇÃO

Onde o RL é Aplicado em Finanças?

Market Making

Objetivo Geral
Lucrar via spread bid-ask provendo liquidez contínua.

Decisões do Agente
Ajuste dinâmico de preços limite e volumes das ordens.

Risco Dominante
Exposição a inventário e seleção adversa.

Portfolio Management

Objetivo Geral
Otimizar alocação de capital entre múltiplos ativos.

Decisões do Agente
Redefinição periódica dos pesos do portfólio (w_t).

Risco Dominante
Volatilidade e perdas severas em bear markets.

Optimal Execution

Objetivo Geral
Liquidar grande bloco de ordens minimizando custos.

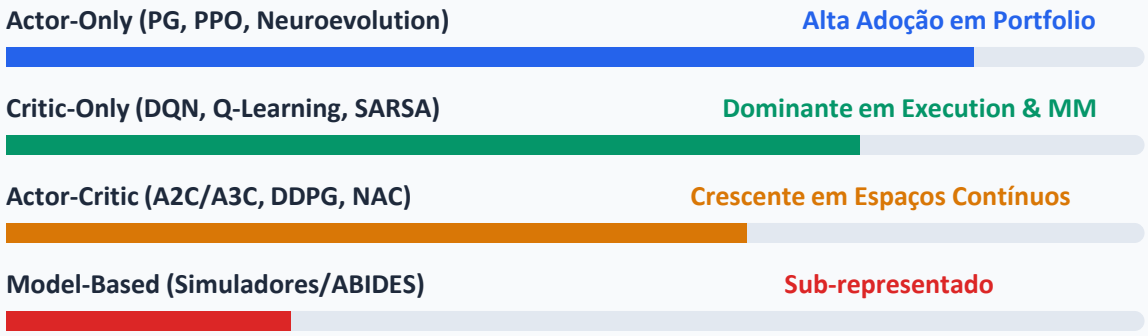
Decisões do Agente
Fracionamento de volume e timing de submissão.

Risco Dominante
Impacto de mercado e slippage temporário.

TAXONOMIA ALGORÍTMICA

Quais Algoritmos São Utilizados na Literatura?

FREQUÊNCIA DE ALGORITMOS



Fonte: Bai et al. (2025), Figura 1, p. 212. Números reportados no levantamento.

Predomínio Model-Free

Métodos *model-free* dominam devido à dificuldade de modelar dinâmicas estocásticas de mercado.

Ações Discretas vs. Contínuas

DQN/SARSA predominam em execução discreta; DDPG/PPO em alocação contínua de carteiras.

Advertência Científica

Frequência de publicação reflete conveniência empírica, **não superioridade de desempenho comprovada**.

RIGORMETRIA DE AVALIAÇÃO

Como Comparar Estudos Heterogêneos?

MÉTRICA DE PADRONIZAÇÃO PROPOSTA

$$\text{RL Premium} = \frac{SR_{RL} - SR_{Baseline}}{SR_{Baseline}}$$

Onde SR_{RL} é o Sharpe Ratio do método RL e $SR_{Baseline}$ do melhor método não-RL considerado no artigo.

Q1 **Design do MDP**

Número de ativos, dimensão do estado e *reward shaping* afetam o ganho relativo?

Q2 **Treinamento e Regimes**

Períodos mais longos ou inclusão da crise de 2008 alteram o desempenho?

Q3 **Escolha do Algoritmo**

Existem diferenças estatisticamente significativas entre Policy Gradient e DQN?

Q4 **Realismo Experimental**

Premissas sobre slippage e custos refletem o ambiente de negociação real?

RESULTADOS EMPÍRICOS — PARTE I

O Design do MDP Melhora o Desempenho?

FIGURA 2(a)

Dimensão do Estado

Inclinação: 0,171
p-valor = 0,499

Tendência positiva leve ao adicionar features (e.g. sentimento), mas sem significância estatística.

NÃO SIGNIFICATIVO

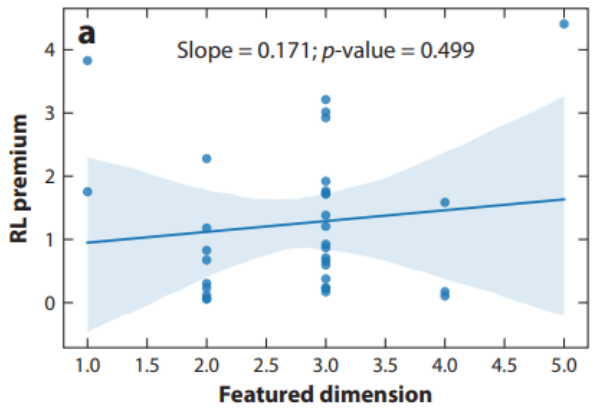


FIGURA 2(b)

Número de Ativos

Inclinação: 0,010
p-valor = 0,362

Aumento do espaço de ação em carteiras maiores não apresentou associação estatística conclusiva.

NÃO SIGNIFICATIVO

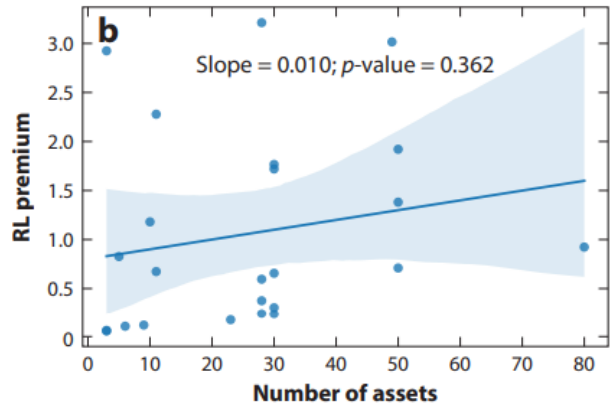


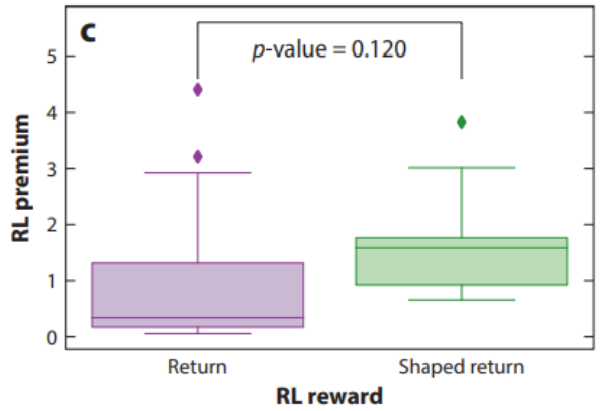
FIGURA 2(c)

Reward Shaping

Comparativo: Return vs. Shaped
p-valor = 0,120

Visualmente favorável a recompensas moldadas (Sharpe ratio ajustado), porém sem significância a 5%.

TENDÊNCIA VISUAL



RESULTADOS EMPÍRICOS — PARTE II

Mais Treinamento ou Outro Algoritmo Resolve?

FIGURA 2(d)

Duração do Treino

Inclinação: 0,023
p-valor = 0,591

Anos adicionais no histórico de treino não garantem maior RL Premium, devido à não-estacionariedade dos dados.

FIGURA 2(e)

Grande Recessão

Inclusão de Crise (2008): SIM / NÃO
p-valor = 0,604

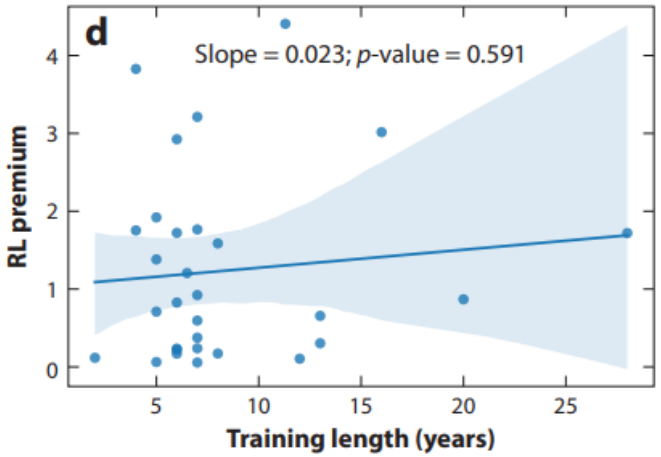
Não foi identificada diferença estatisticamente relevante na performance de agentes treinados com períodos de recessão.

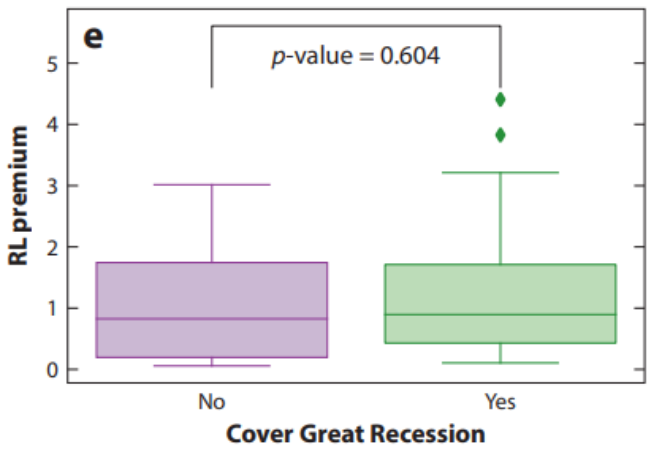
FIGURA 2(f)

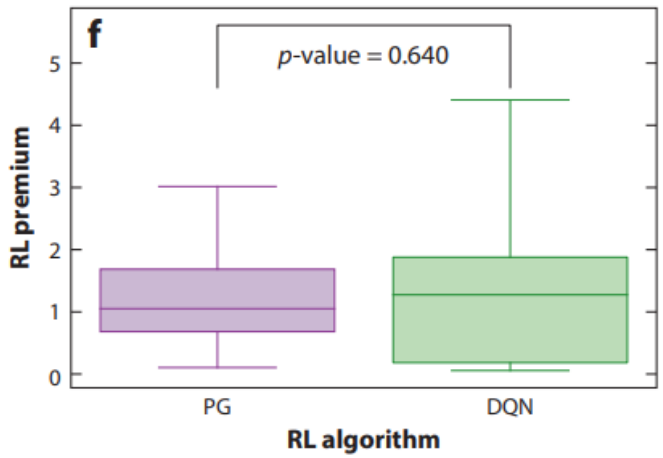
PG vs. DQN

Comparativo: Policy Gradient vs DQN
p-valor = 0,640

Ausência de diferença estatística na amostra analisada. PG não é intrinsecamente superior ao DQN na literatura examinada.







VALIDADE DE SIMULAÇÃO

Um Bom Backtest Representa o Mercado Real?

Mapeamento de Premissas

Slippage Considerado:

~80% dos artigos

Assumem slippage zero ou omitem o tratamento.

Custos de Transação:

0,2% – 0,3%

Faixa padrão na literatura, porém variável na prática.

Fonte: Bai et al. (2025), Figura 3, p. 222.

Exo-MDP e Replay Histórico

Validade em Portfolio Management: Válido quando o mercado é aproximadamente exógeno às ações do agente ($P(x_{t+1} \mid s_t, a_t) = P(x_{t+1} \mid x_t)$).

Falha em Optimal Execution

Inadequação de Replay Simples: Operações do agente alteram o mercado (*market impact*). Exige simuladores multiagente fiéis como ABIDES.

DIAGNÓSTICO DA LITERATURA

O que Ainda Impede a Adoção Robusta de RL?

Peculiaridades dos Dados

- **Alta Volatilidade & Ruído:** Razão sinal-ruído extremamente baixa.
- **Caudas Pesadas:** Eventos extremos mais frequentes que o modelo Gaussiano.
- **Não-Estacionariedade:** Mudanças estruturais de regime de mercado.
- **Observabilidade Parcial:** Informações latentes e long-range dependency.

Limitações Metodológicas

- **Falta de Explicabilidade:** Modelos "caixa-preta" barram adoção institucional.
- **Modelagem do MDP:** Dificuldade na escolha de estados e recompensas.
- **Ausência de Benchmarks:** Ambientes não padronizados (com exceções como FinRL).
- **Sim-to-Real Gap:** Políticas de simulação falham em produção.

Ressalva da Meta-Análise: Os autores ressaltam que os estudos revisados possuem heterogeneidade e potenciais variáveis de confusão não controladas.

AGENDA DE PESQUISA & SÍNTESE

Para Onde a Pesquisa Deve Avançar?

01. MULTI-AGENT

Multi-Agent RL

Modelagem de competição, ordens adversariais e dinâmica interativa.

02. MODEL-BASED

Model-Based RL

Construção de simuladores fidedignos para planejamento e eficiência.

03. OFFLINE RL

Offline RL

Aprendizado direto de trajetórias históricas sem exploração online.

04. RISK-SENSITIVE

Risk-Sensitive RL

Incorporação de restrições de risco nos algoritmos de otimização.

Mensagem final

RL apresenta resultados promissores em finanças, mas sua adoção confiável depende de MDPs bem formulados, avaliações realistas, robustez e benchmarks comparáveis.