PPGTI / UFRN — DISCIPLINA DE APRENDIZADO POR REFORÇO

Experimentos em Aprendizado por Reforço

Rafael Pereira de Alexandria Soares

Objetivo

Consolidar teoria via experimentação prática.

Algoritmos

Tabulares: SARSA(0), Q-Learning(0).
Profundos: DQN, DDQN.

Ambientes

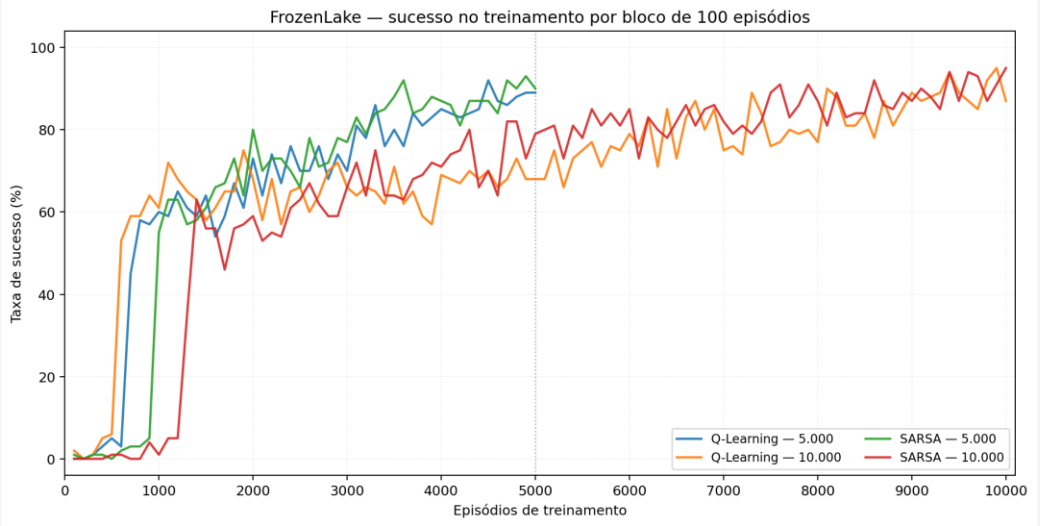
FrozenLake, Blackjack, CliffWalking, Taxi, CartPole, MountainCar, Pong, Space Invaders.

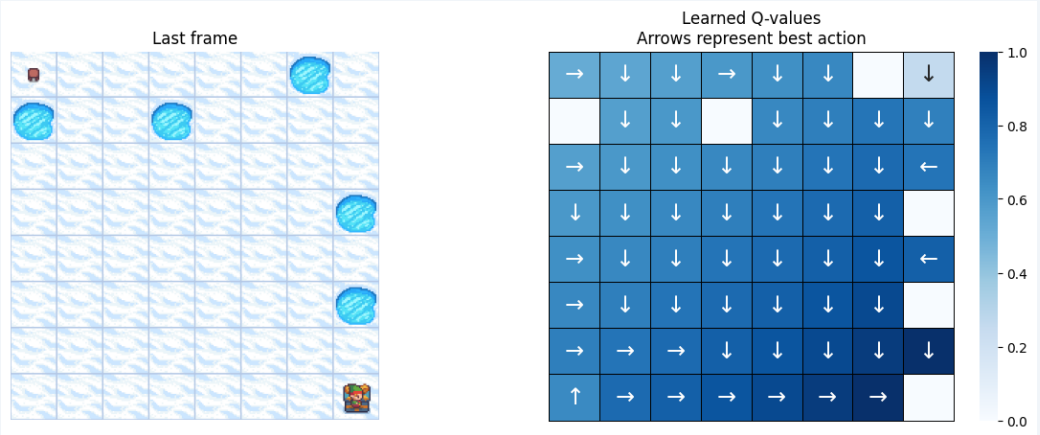
Internal Use

FrozenLake: aprendizado e estabilidade

Ambos os algoritmos resolveram a tarefa, com diferenças na estabilidade.

- **Horizontes:** Treinamentos de 5.000 e 10.000 episódios.
- **Eficácia:** Sucesso final satisfatório nas quatro configurações.
- **Q-Learning:** Maior regularidade nas avaliações periódicas.
- **SARSA:** Oscilações frequentes durante o treinamento.





Blackjack: resultados próximos entre algoritmos

Desempenho semelhante e amplamente superior à política aleatória.

42,59%

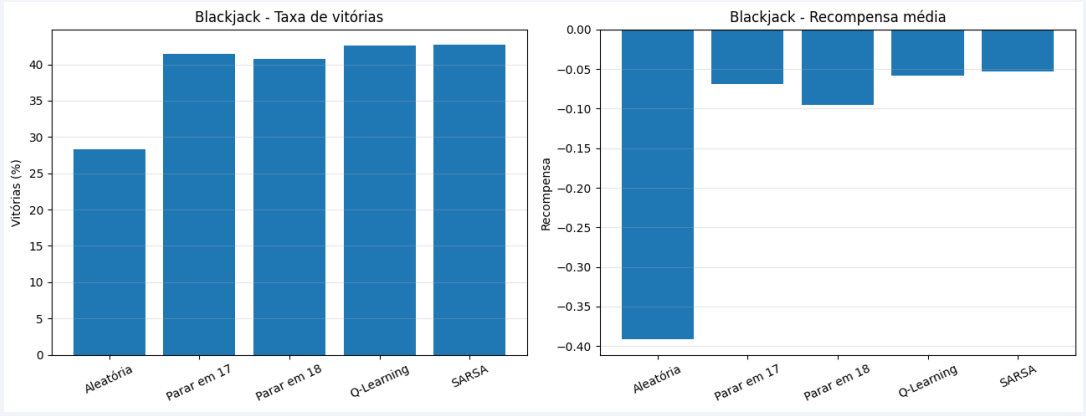
VITÓRIAS Q-LEARNING

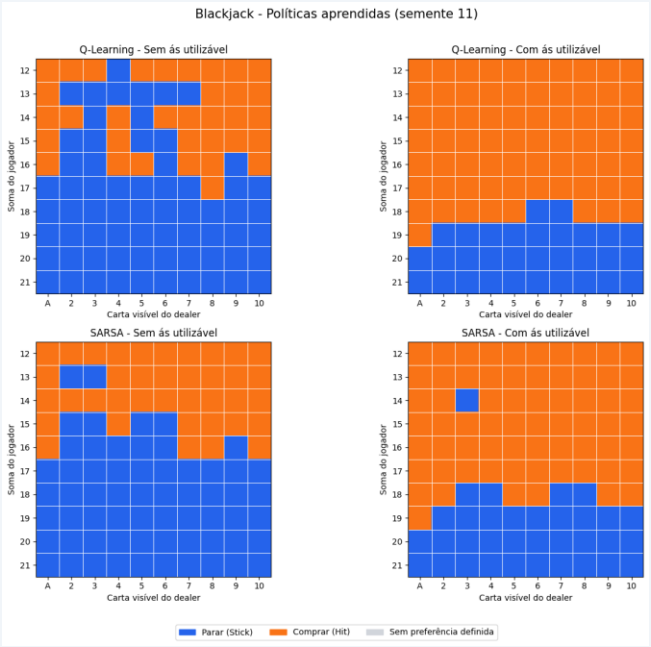
42,67%

VITÓRIAS SARSA

28,32%

REFERÊNCIA ALEATÓRIA

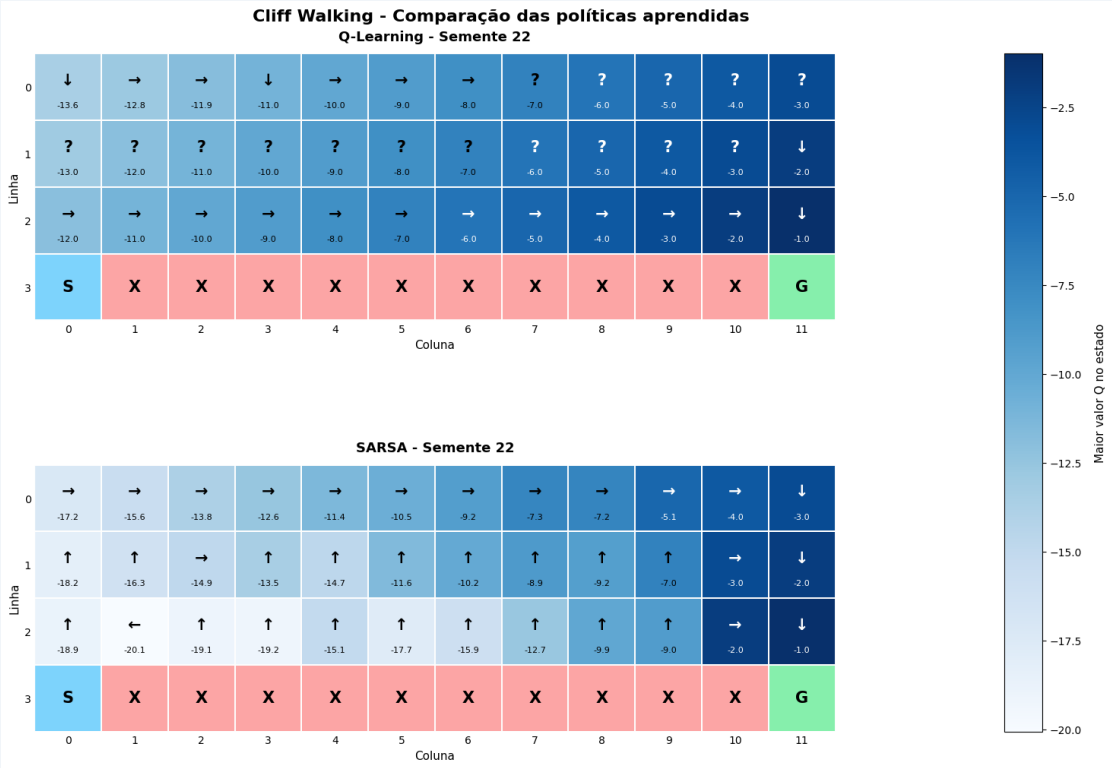




Internal Use

CliffWalking: eficiência versus risco

A trajetória mais curta não é a mais segura sob exploração ativa.

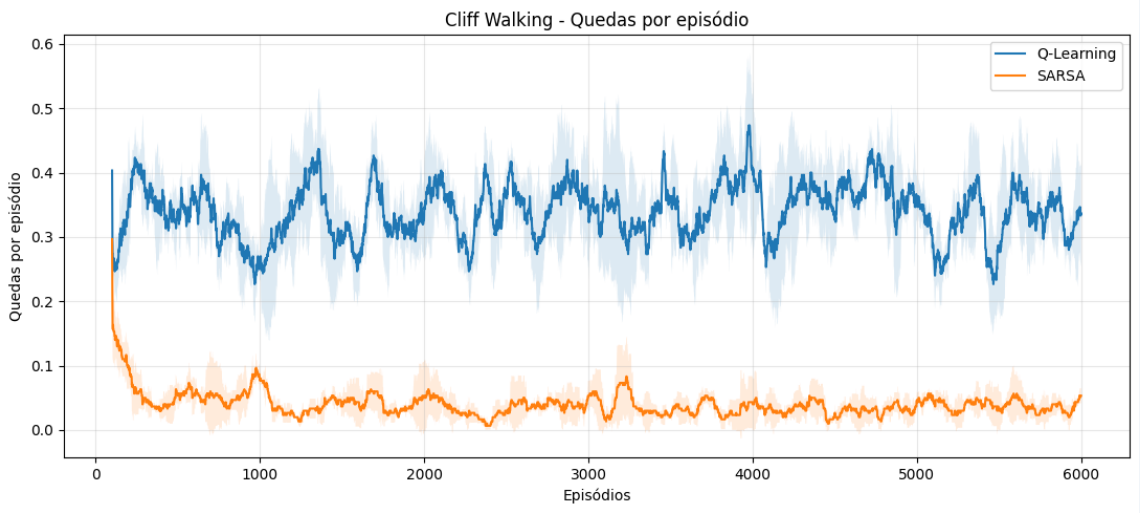


- **Q-Learning:** Trajetórias gulosas de 13 passos (rente ao abismo).
- **SARSA:** Trajetórias conservadoras de 17 passos.
- **Limitação:** Uma semente SARSA falhou na avaliação gulosa.
- **Exploração:** 23,7% de quedas no Q-Learning; apenas 2,8% no SARSA.

Internal Use

CliffWalking: eficiência versus risco

A trajetória mais curta não é a mais segura sob exploração ativa.



- **Q-Learning:** Trajetórias gulosas de 13 passos (rente ao abismo).
- **SARSA:** Trajetórias conservadoras de 17 passos.
- **Limitação:** Uma semente SARSA falhou na avaliação gulosa.
- **Exploração:** 23,7% de quedas no Q-Learning; apenas 2,8% no SARSA.

Internal Use

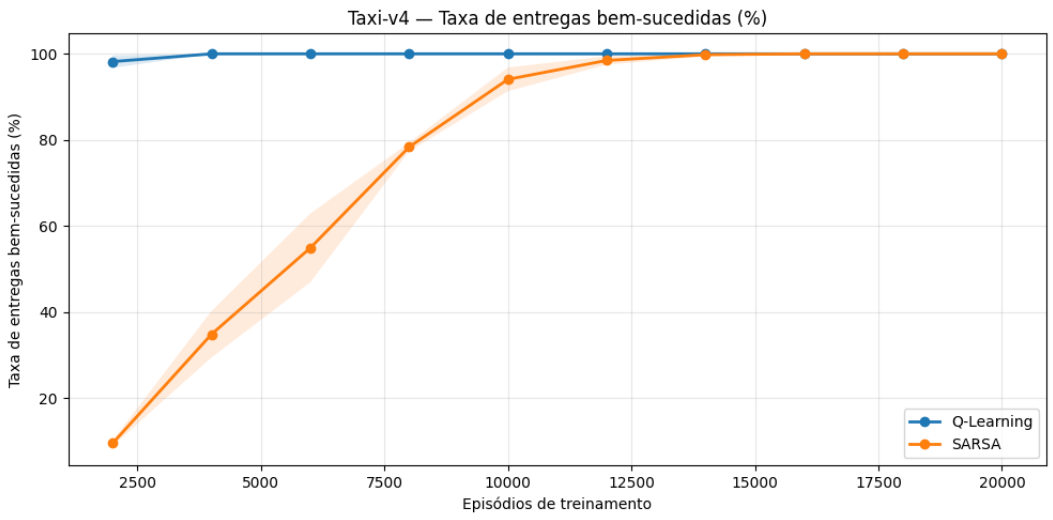
Taxi: velocidade de aprendizagem

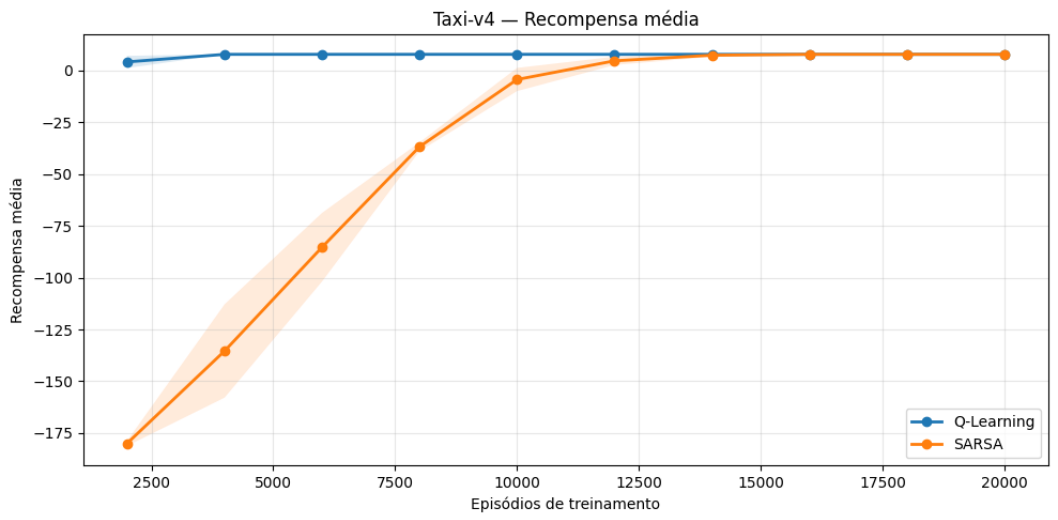
Mesmo desempenho final, mas Q-Learning aprendeu mais rápido.

Q-Learning Rápido
100% de entregas em 4.000 episódios.

SARSA Gradual
100% de entregas em 16.000 episódios.

Convergência Final
Ambos 100% sucesso (+7,949 pts).



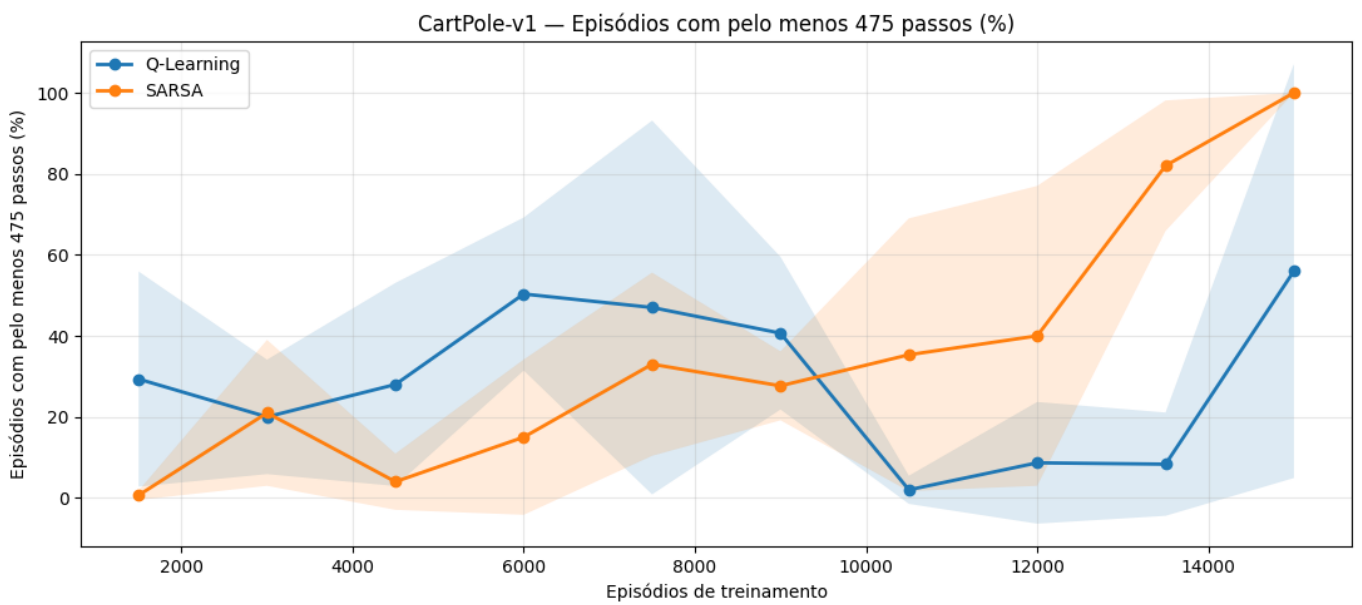


Internal Use

CartPole: algoritmos tabulares

Refinamento da discretização favoreceu o SARSA de forma consistente.

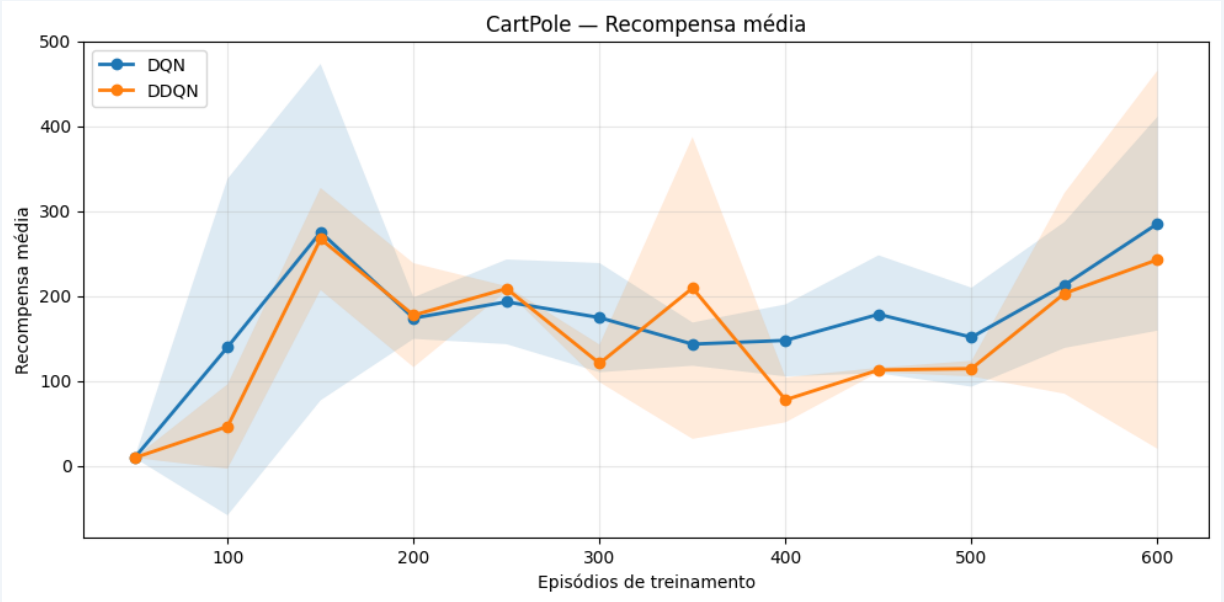
- **Discretização:** Duas configurações espaciais testadas.
- **Q-Learning (B):** Recompensa média final de 389,483.
- **SARSA (B):** Recompensa média máxima de 500,000.
- **Robustez:** SARSA atingiu limite em 100% das 600 partidas finais.
- **Variabilidade:** Refinamento não beneficiou sementes do Q-Learning uniformemente.



Internal Use

CartPole: DQN versus DDQN

Aprendizado profundo mostrou extrema sensibilidade à semente e exploração.



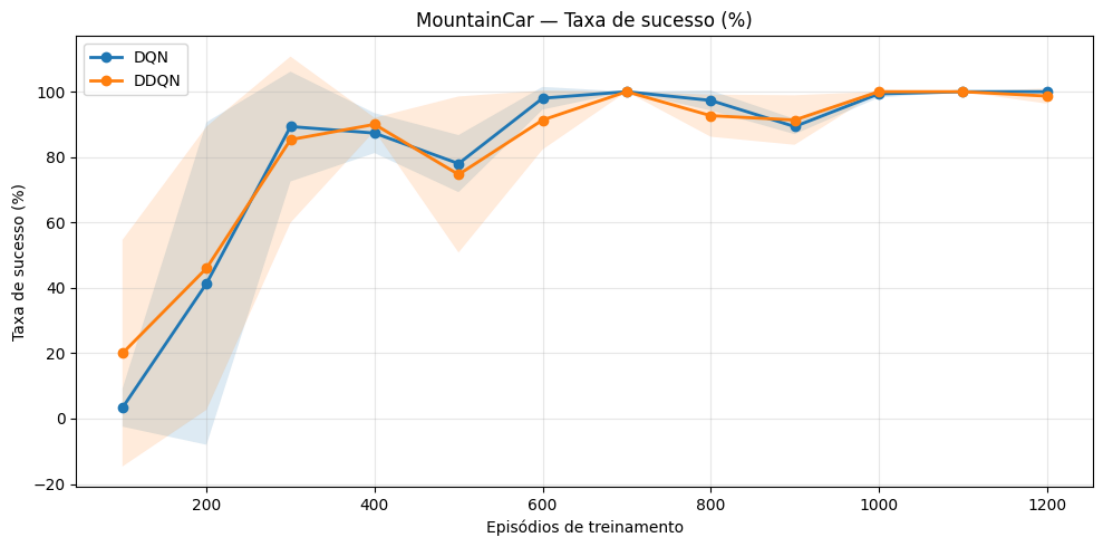
- **Média Final (B):** DQN: 276,503 | DDQN: 242,557.
- **Extremos:** DDQN semente 11 atingiu 500 pts; outras falharam.
- **Instabilidade:** Resultados mostram ausência de superioridade uniforme.
- **Comparação:** Orçamentos diferentes impedem conclusão sobre tabulares vs redes.

Internal Use

MountainCar: aprendizado com demonstrações

Treinamento híbrido superou o desafio das recompensas esparsas.

- **Auxílio:** 80 trajetórias demonstrativas prévias (9.565 transições).
- **Mistura:** 25% de cada minibatch proveniente das demonstrações.
- **Sucesso Final:** DQN: 100% de eficácia. DDQN: 98,67%.
- **Ressalva:** Sem auxílio demonstrativo, o treinamento inicial autônomo não convergira.



Internal Use

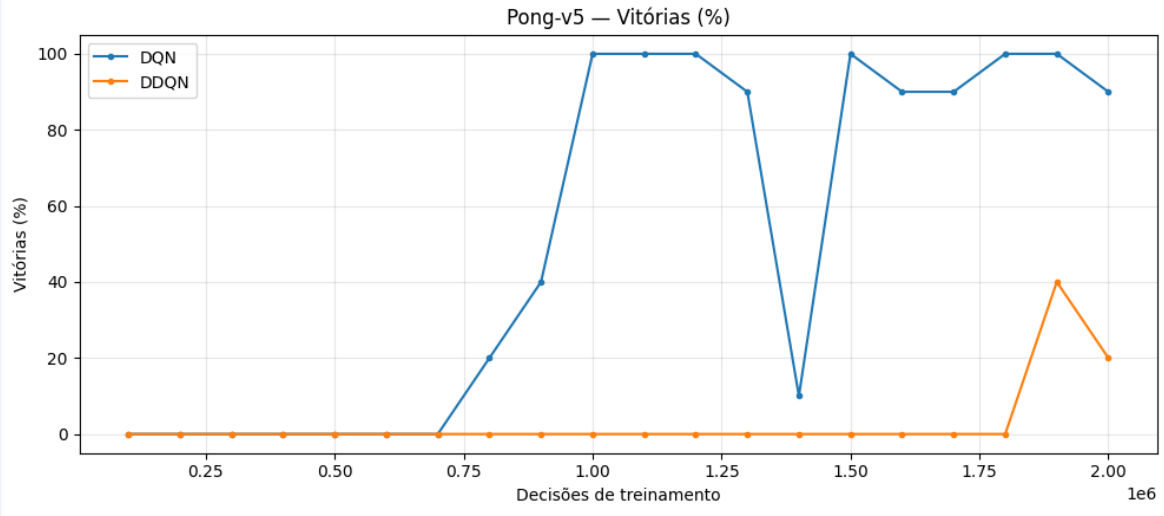
Pong: DQN supera DDQN após 2M de decisões

Treinamento prolongado de 2.000.000 decisões (CNN, 1 semente).

DQN — VITÓRIAS
93,3%
+12,10 Recompensa

DDQN — VITÓRIAS
30,0%
−2,13 Recompensa

Indicador (30 partidas)	DQN	DDQN
Vitórias absolutas	28	9
Pontos marcados p/ partida	20,93	17,77
Pontos sofridos p/ partida	8,83	19,90



Indicador	DQN	DDQN
Decisões de treinamento	2.000.000	2.000.000
Episódios completos no treinamento	1.158	1.283
Recompensa média final	+12,100	−2,133
Pontos marcados médios	20,933	17,767
Pontos sofridos médios	8,833	19,900
Vitórias (partidas)	28/30	9/30
Taxa de vitórias (%)	93,333	30,000
Decisões médias por partida	2.138,833	2.595,833
Truncamentos (%)	0,000	0,000

Internal U

Space Invaders: aprendizado visual

Ambos os agentes superaram a referência aleatória, sem avanço monotônico.

151,50

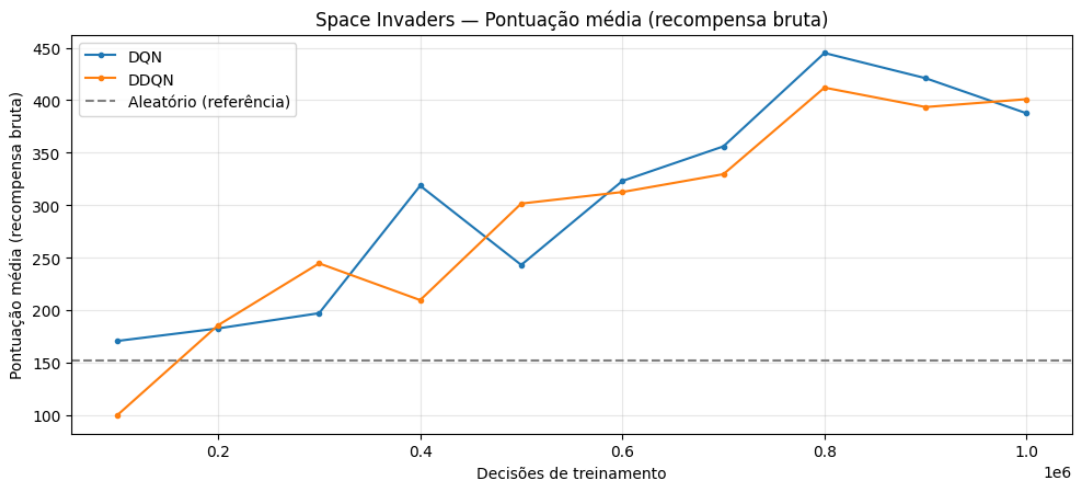
AGENTE ALEATÓRIO

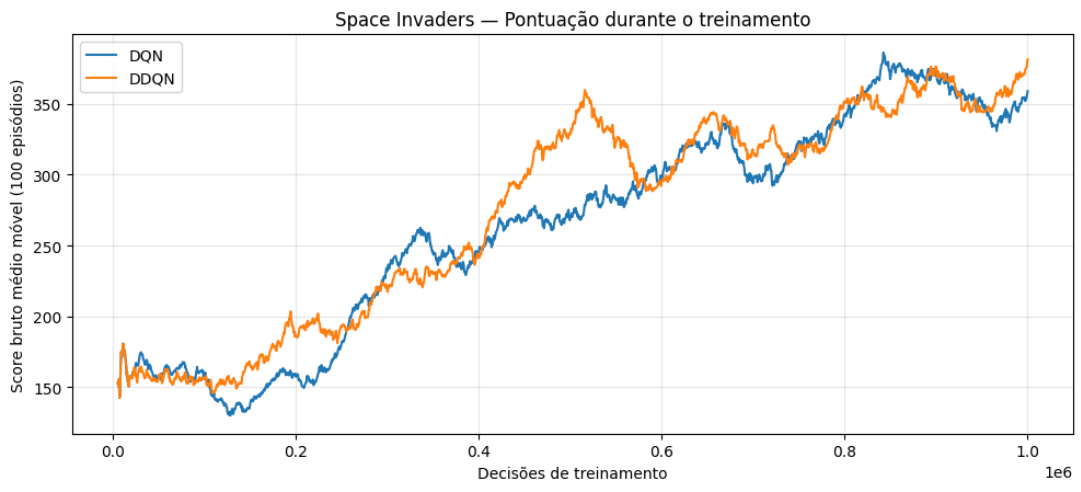
381,67

MÉDIA DQN

444,17

MÉDIA DDQN





Internal Use

O que os experimentos demonstraram?

Desempenho atrelado a exploração, recompensas e representação.

Exploração e Estabilidade

FrozenLake e CliffWalking confirmaram impactos distintos de políticas On e Off-Policy nos riscos assumidos.

Eficiência Tabular

No Taxi, recompensas máximas idênticas foram atingidas em ritmos expressivamente diferentes.

Representação de Estados

CartPole tabular evidenciou que refinar discretização eleva o teto, mas agrava a esparsidade.

Variabilidade Neural

CartPole profundo demonstrou extrema sensibilidade a sementes e parâmetros de exploração.

Auxílio Externo

MountainCar revelou o peso determinante de adicionar demonstrações prévias ao Replay Buffer.

Orçamento Visual

Pong: Treinamento prolongado possibilitou políticas eficazes, mas expôs oscilações expressivas e diferenças claras entre DQN e DDQN.

Internal Use

Principais Conclusões

1. Aplicações práticas consolidaram o entendimento teórico dos métodos tabulares e profundos.

2. Ausência de superioridade uniforme; a arquitetura ótima variou conforme exploração e representação.

3. Estabilidade no treino, variabilidade entre sementes e qualidade das experiências balizam o desempenho.

Internal Use

OBRIGADO

Internal Use