UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE
PROGRAMA DE PÓS-GRADUAÇÃO EM TECNOLOGIA DA INFORMAÇÃO
PPgTI

RELATÓRIO DE EXPERIMENTOS EM APRENDIZADO POR REFORÇO

RAFAEL PEREIRA DE ALEXANDRIA SOARES

Natal – RN
2026

Sumário

1 Introdução **2**

2 Fundamentação Teórica **2**
2.1 Fundamentos do Aprendizado por Reforço 2
2.2 Aprendizado por Diferença Temporal e Exploração 2
2.3 Algoritmos Utilizados 3
2.4 Ambientes 4

3 Metodologia Experimental **6**
3.1 Configuração dos Experimentos 6
3.2 Procedimentos de Treinamento e Avaliação 11

4 Resultados **14**
4.1 Resultados: FrozenLake-v1 14
4.2 Resultados: Blackjack-v1 17
4.3 Resultados: CliffWalking-v1 20
4.4 Resultados: Taxi-v4 24
4.5 Resultados: CartPole-v1 27
4.6 Resultados: DQN e DDQN no CartPole-v1 30
4.7 Resultados: DQN e DDQN no MountainCar-v0 33
4.8 Resultados: Space Invaders-v5 36
4.9 Resultados: Pong-v5 37

5 Discussão **39**
5.1 Discussão: FrozenLake-v1 39
5.2 Discussão: Blackjack-v1 39
5.3 Discussão: CliffWalking-v1 39
5.4 Discussão: Taxi-v4 40
5.5 Discussão: CartPole-v1 40
5.6 Discussão: DQN e DDQN no CartPole-v1 40
5.7 Discussão: DQN e DDQN no MountainCar-v0 41
5.8 Discussão: DQN e DDQN no Space Invaders-v5 41
5.9 Discussão: DQN e DDQN no Pong-v5 41

6 Conclusões **42**

Referências **43**

1. Introdução

Este relatório apresenta os experimentos da disciplina de Aprendizado por Reforço do Programa de Pós-Graduação em Tecnologia da Informação (PPgTI) da Universidade Federal do Rio Grande do Norte (UFRN), realizados para consolidar, por meio de implementações e avaliações práticas, os conceitos estudados em sala.

Utilizaram-se os ambientes FrozenLake, Blackjack, CliffWalking, Taxi, CartPole, MountainCar, Pong e Space Invaders da biblioteca Gymnasium, abrangendo navegação, decisões estocásticas, controle e jogos baseados em imagens.

Foram implementados os métodos tabulares SARSA(0) e Q-Learning(0) e os métodos profundos *Deep Q-Network* (DQN) e *Double Deep Q-Network* (DDQN). As análises consideram recompensas, políticas aprendidas, evolução do treinamento, hiperparâmetros e limitações de cada protocolo experimental.

2. Fundamentação Teórica

2.1. Fundamentos do Aprendizado por Reforço

No aprendizado por reforço, um agente interage com o ambiente e aprende uma política para maximizar recompensas acumuladas, sem exemplos rotulados das ações corretas (Sutton e Barto, 2018).

A interação é modelada por um Processo de Decisão de Markov (MDP): no instante t, o agente observa s_t, escolhe a_t, recebe r_t e transita para s_{t+1}. A política $\pi(a|s)$ especifica a probabilidade de cada ação em um estado.

A função $Q^\pi(s, a)$ representa o retorno esperado ao executar a em s e seguir π. O retorno descontado é:

$$G_t = \sum_{k=0}^{T-t-1} \gamma^k r_{t+k}, \tag{1}$$

em que γ é o fator de desconto e T representa o instante terminal do episódio. Valores menores de γ reduzem a influência das recompensas futuras, enquanto valores próximos de 1 atribuem maior importância aos retornos de longo prazo (Sutton e Barto, 2018).

2.2. Aprendizado por Diferença Temporal e Exploração

Métodos de diferença temporal atualizam valores com recompensas observadas e estimativas futuras, sem conhecer o modelo de transição do ambiente (Sutton, 1988).

Uma política ε-greedy equilibra exploração e aproveitamento: escolhe aleatoriamente com probabilidade ε e seleciona uma ação de maior valor estimado caso contrário. Em geral, a exploração diminui durante o treinamento (Sutton e Barto, 2018).

2.3. Algoritmos Utilizados

2.3.1 SARSA(0)

O SARSA(0), associado a Rummery e Niranjan (1994), é um método *on-policy*: sua atualização depende da próxima ação escolhida pela política em execução (Sutton e Barto, 2018).

O nome SARSA corresponde aos elementos da transição utilizados na atualização: estado, ação, recompensa, próximo estado e próxima ação. A regra de atualização é:

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[r_t + \gamma(1 - d_t) Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t) \right], \tag{2}$$

em que α representa a taxa de aprendizado e $d_t = 1$ indica uma terminação efetiva. A próxima ação a_{t+1} é selecionada pela própria política de comportamento.

Ao incorporar as ações exploratórias aos alvos, o SARSA pode valorizar rotas menos arriscadas, aspecto investigado no CliffWalking.

2.3.2 Q-Learning(0)

O Q-Learning(0) é um método *off-policy*: o alvo usa o maior valor no estado sucessor, independentemente da próxima ação executada (Watkins e Dayan, 1992).

Sua regra de atualização é expressa por:

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[r_t + \gamma(1 - d_t) \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t) \right]. \tag{3}$$

Assim, uma política exploratória pode gerar experiências para estimar valores de uma política gulosa. Sob condições adequadas, o método tabular possui garantias de convergência (Watkins e Dayan, 1992).

SARSA(0) e Q-Learning(0) utilizam tabelas Q nos problemas discretos; espaços contínuos ou de alta dimensão motivam a aproximação por funções (Sutton e Barto, 2018).

2.3.3 Deep Q-Network (DQN)

O DQN substitui a tabela Q por uma rede neural parametrizada por θ, capaz de aproximar $Q(s, a; \theta)$ (Mnih et al., 2015).

Neste trabalho, empregam-se redes densas em tarefas de controle clássico e convolucionais para as observações visuais dos jogos Atari.

Para estabilizar a otimização, o DQN combina memória de experiências (*experience replay*), que reutiliza transições amostradas (Lin, 1992), e rede-alvo com parâmetros atualizados periodicamente.

O alvo de treinamento do DQN é definido por:

$$y_t^{\mathrm{DQN}} = r_t + \gamma(1 - d_t) \max_{a'} Q(s_{t+1}, a'; \theta^-), \tag{4}$$

em que θ^- representa os parâmetros da rede-alvo. A rede online é ajustada por otimização do erro entre o valor estimado e o alvo temporal, possibilitando aprender diretamente a partir das experiências coletadas.

2.3.4 Double Deep Q-Network (DDQN)

O *Double Deep Q-Network* (DDQN) foi proposto por van Hasselt et al. (2016) como uma extensão do DQN baseada no princípio de dupla estimação apresentado anteriormente por van Hasselt (2010).

O DDQN busca reduzir a superestimação introduzida pela maximização, selecionando a próxima ação com a rede online e avaliando-a com a rede-alvo:

$$a_t^* = \arg\max_{a'} Q(s_{t+1}, a'; \theta), \qquad y_t^{\mathrm{DDQN}} = r_t + \gamma(1 - d_t) Q(s_{t+1}, a_t^*; \theta^-). \tag{5}$$

A separação reduz a propensão à superestimação sem modificar a arquitetura; isso não assegura maior recompensa em toda execução (van Hasselt et al., 2016).

Na comparação experimental, DQN e DDQN diferem no cálculo do alvo temporal, mantendo condições equivalentes dentro de cada configuração.

2.4. Ambientes

A Gymnasium fornece uma interface padronizada para executar e avaliar agentes em diferentes ambientes (Towers et al., 2024).

As tarefas abrangem *Toy Text*, *Classic Control* e Atari; neste último, utiliza-se a *Arcade Learning Environment* (ALE) (Bellemare et al., 2013).

2.4.1 FrozenLake-v1

No `FrozenLake-v1`, o agente navega em uma grade 8×8 (64 estados), do início (S) até o objetivo (G), evitando buracos (H). Há quatro ações cardeais; a recompensa é 1 no objetivo e 0 nos demais estados. O episódio termina ao chegar, cair ou atingir 100 passos.

Utilizou-se `is_slippery=False` (transições determinísticas) e um mapa fixo gerado com probabilidade de congelamento $p = 0{,}9$. A recompensa positiva ocorre apenas na meta.

2.4.2 Blackjack-v1

No `Blackjack-v1`, o agente decide comprar (*hit*, ação 1) ou parar (*stick*, ação 0). O estado (p, d, u) contém a soma do jogador, a carta visível do dealer e a presença de ás utilizável (valor 11 sem ultrapassar 21).

As cartas são estocásticas; o dealer compra até somar pelo menos 17. A recompensa terminal é $+1$ (vitória), 0 (empate) ou -1 (derrota), com `natural=False` e `sab=False`.

O desafio é escolher entre risco de estourar e possibilidade de melhorar a mão sem conhecer as cartas futuras.

2.4.3 CliffWalking-v1

O `CliffWalking-v1` apresenta uma grade 4×12 (48 estados). O agente parte do estado 36 e busca o estado 47, evitando dez posições de precipício na última linha. As ações são cima (0), direita (1), baixo (2) e esquerda (3).

Cada passo custa -1; uma queda custa -100 e devolve o agente ao início, sem encerrar o episódio. O objetivo encerra a partida; as transições são determinísticas (`is_slippery=False`) e adotou-se limite experimental de 200 passos.

O ambiente contrapõe o menor caminho próximo ao precipício e rotas mais longas e seguras, permitindo estudar políticas *on-policy* e *off-policy*.

2.4.4 Taxi-v4

O `Taxi-v4` simula embarque, transporte e desembarque em grade 5×5, com 500 estados que codificam posição do veículo, passageiro e destino. São seis ações: sul (0), norte (1), leste (2), oeste (3), embarcar (4) e desembarcar (5).

As recompensas são -1 por ação ordinária, -10 por embarque/desembarque incorreto penalizado e $+20$ por entrega válida. O limite é de 200 passos. Utilizaram-se `is_rainy=False` e `fickle_passenger=False`, sem máscaras de ações válidas.

A tarefa exige combinar navegação e ações contextuais, avaliando eficiência, entregas concluídas e penalidades.

2.4.5 CartPole-v1

No `CartPole-v1`, o agente aplica força para esquerda (0) ou direita (1) a fim de equilibrar uma haste articulada sobre um carrinho.

O estado contém posição e velocidade do carrinho $(x, \dot{x})$ e ângulo e velocidade angular da haste $(\theta, \dot{\theta})$. Cada passo rende $+1$, até 500; falha física termina o episódio e o limite temporal o trunca.

Para SARSA(0) e Q-Learning(0), as quatro observações contínuas foram convertidas em intervalos discretos, permitindo tabelas Q, mas com perda de resolução.

Compararam-se discretizações $6 \times 6 \times 12 \times 12$ (A) e $8 \times 8 \times 16 \times 16$ (B), para investigar a influência da granularidade.

Para DQN e DDQN, as quatro observações foram fornecidas diretamente às redes. A comparação com os métodos tabulares é descritiva, pois os orçamentos experimentais não foram equivalentes.

2.4.6 MountainCar-v0

O `MountainCar-v0` exige que um veículo alcance a bandeira à direita acumulando energia em movimentos alternados. O estado contém posição e velocidade, e as ações são acelerar à esquerda (0), não acelerar (1) ou acelerar à direita (2).

A meta é $x \geq 0{,}5$ em até 200 passos. A recompensa é -1 por passo, totalizando -200 em episódios sem sucesso; não há reforço adicional pela aproximação à meta.

Após tentativas preliminares sem orientação, gerou-se uma memória demonstrativa por uma política baseada no sinal da velocidade: acelerar à direita se $v \geq 0$ e à esquerda se $v < 0$. DQN e DDQN utilizaram essas experiências sem modificar a recompensa. Trata-se, portanto, de aprendizagem *com demonstrações*, não exclusivamente autônoma.

2.4.7 Space Invaders-v5

O `ALE/SpaceInvaders-v5`, disponibilizado pela *Arcade Learning Environment* (ALE), é um jogo Atari no qual o agente controla uma nave para eliminar inimigos e acumular pontos (Bellemare et al., 2013). O ambiente apresenta observações visuais e seis ações discretas. Seu uso permite investigar a aprendizagem de políticas a partir de imagens e recompensas obtidas durante a partida.

2.4.8 Pong-v5

O `ALE/Pong-v5`, disponibilizado pela *Arcade Learning Environment* (ALE), simula uma partida em que o agente controla uma raquete para rebater a bola e superar o adversário (Bellemare et al., 2013). Cada ponto conquistado fornece recompensa $+1$, enquanto cada ponto sofrido gera -1. As observações visuais e as recompensas associadas aos pontos tornam o ambiente adequado para investigar a aprendizagem por reforço profundo a partir de imagens.

3. Metodologia Experimental

3.1. Configuração dos Experimentos

3.1.1 FrozenLake-v1

No FrozenLake-v1, SARSA(0) e Q-Learning(0) foram treinados por 5.000 ou 10.000 episódios, no mesmo mapa de cinco buracos. Utilizaram-se $\alpha = 0{,}5$, $\gamma = 0{,}95$ e ε-greedy com decaimento linear de 0,5 a 0,1, conforme a Equação 6.

$$\varepsilon_t = \max\left(\varepsilon_{\min}, \varepsilon_0 - t\frac{\varepsilon_0 - \varepsilon_{\min}}{N}\right) \tag{6}$$

em que ε_0 representa a exploração inicial, $\varepsilon_{\min}$ a exploração mínima, t o número de episódios concluídos e N o número total de episódios de treinamento.

Como ε depende do horizonte N, as execuções de 10.000 episódios também tiveram

decaimento de exploração mais lento.

A Tabela 1 apresenta os parâmetros empregados.

Tabela 1: Parâmetros experimentais utilizados no FrozenLake-v1.

Parâmetro	**5.000 ep.**	**10.000 ep.**
Taxa de aprendizado (α)	0,5	0,5
Fator de desconto (γ)	0,95	0,95
Exploração inicial (ε_0)	0,5	0,5
Exploração mínima ($\varepsilon_{\min}$)	0,1	0,1
Decaimento de ε por episódio	0,00008	0,00004
Frequência de avaliação	100	100
Episódios por avaliação	50	50
Passos máximos por episódio	100	100

3.1.2 Blackjack-v1

No Blackjack-v1, cada algoritmo foi executado com sementes 11, 22 e 33, por 100.000 episódios, inicializando Q em zero. Adotaram-se $\alpha = 0{,}05$, $\gamma = 1$ e decaimento linear de $\varepsilon = 1$ para 0,05.

Tabela 2: Configuração experimental de SARSA(0) e Q-Learning(0) no Blackjack-v1.

Parâmetro	**Valor**
Episódios por treinamento	100.000
Sementes de treinamento	11, 22 e 33
Taxa de aprendizado (α)	0,05
Fator de desconto (γ)	1,0
Exploração inicial (ε_0)	1,0
Exploração final (ε_f)	0,05
Intervalo de avaliação	10.000 episódios
Partidas por avaliação periódica	2.000
Partidas por avaliação final	10.000

3.1.3 CliffWalking-v1

No CliffWalking-v1, cada algoritmo foi treinado por 3.000 ou 6.000 episódios, nas sementes 11, 22 e 33, com tabelas nulas, $\alpha = 0{,}5$, $\gamma = 1$ e $\varepsilon = 0{,}1$ constante. São doze treinamentos independentes.

A Tabela 3 resume as condições adotadas.

3.1.4 Taxi-v4

No Taxi-v4, SARSA(0) e Q-Learning(0) foram executados por 20.000 episódios, nas sementes 11, 22 e 33, com Q inicializada em zero, $\alpha = 0{,}1$, $\gamma = 0{,}99$ e decaimento linear de $\varepsilon = 1$ a 0,05.

Tabela 3: Configuração dos experimentos no CliffWalking-v1.

Parâmetro	**Valor**
Ambiente	`CliffWalking-v1`
Dimensões e estados	4×12; 48 estados
Algoritmos	Q-Learning(0) e SARSA(0)
Episódios por treinamento	3.000 e 6.000
Sementes	11, 22 e 33
Taxa de aprendizado (α)	0,5
Fator de desconto (γ)	1,0
Exploração (ε)	0,1, constante
Passos máximos por episódio	200
Episódios por avaliação final	300
Modos de avaliação	$\varepsilon = 0$ e $\varepsilon = 0{,}1$

Tabela 4: Configuração experimental dos algoritmos no Taxi-v4.

Parâmetro	**Valor**
Ambiente	`Taxi-v4` (Gymnasium 1.4.0)
Estados e ações	500 estados; 6 ações
Algoritmos	Q-Learning(0) e SARSA(0)
Episódios por treinamento	20.000
Sementes de treinamento	11, 22 e 33
Taxa de aprendizado (α)	0,1
Fator de desconto (γ)	0,99
Exploração inicial (ε_0)	1,0
Exploração final (ε_f)	0,05
Frequência de avaliação	2.000 episódios
Episódios por avaliação periódica	500
Episódios por avaliação final	3.000
Limite de passos por episódio	200
Uso de máscara de ações	Não

3.1.5 CartPole-v1

No CartPole-v1 tabular, realizaram-se doze treinamentos: dois algoritmos, duas discretizações e três sementes (11, 22 e 33). Cada execução teve 15.000 episódios, $\alpha = 0{,}15$, $\gamma = 0{,}99$ e decaimento linear de $\varepsilon = 1$ a 0,02.

A discretização A contém $6 \times 6 \times 12 \times 12 = 5.184$ estados (10.368 valores Q) e B, $8 \times 8 \times 16 \times 16 = 16.384$ estados (32.768 valores Q). Os limites, comuns às duas, foram $[-2{,}4; 2{,}4]$ para posição, $[-3; 3]$ para velocidade, $[-0{,}2095; 0{,}2095]$ para ângulo e $[-3{,}5; 3{,}5]$ para velocidade angular; valores excedentes foram atribuídos aos intervalos extremos.

Tabela 5: Parâmetros dos experimentos tabulares no CartPole-v1.

Parâmetro	**Valor**
Algoritmos	Q-Learning(0) e SARSA(0)
Discretização A	$6 \times 6 \times 12 \times 12$
Discretização B	$8 \times 8 \times 16 \times 16$
Episódios por treinamento	15.000
Sementes	11, 22 e 33
Taxa de aprendizado (α)	0,15
Fator de desconto (γ)	0,99
Exploração inicial (ε_0)	1,0
Exploração final (ε_f)	0,02
Intervalo de avaliação	1.500 episódios
Partidas por avaliação periódica	100
Partidas por avaliação final	200
Máximo de passos por episódio	500

3.1.6 CartPole-v1: DQN e DDQN

No CartPole-v1 profundo, DQN e DDQN foram treinados em duas configurações que diferiram apenas no decaimento de ε: 35.000 interações (A) ou 15.000 (B), de 1 a 0,05. Foram 600 episódios por algoritmo e semente (11, 22 e 33), totalizando doze treinamentos.

Utilizou-se MLP $4 \to 128 \to 128 \to 2$ (17.410 parâmetros), Adam, perda de Huber, taxa 10^{-3}, $\gamma = 0{,}99$, *replay buffer* de 50.000 transições, minibatch 64, início da otimização após 1.000 amostras, atualização a cada quatro passos e sincronização da rede-alvo a cada 500.

3.1.7 MountainCar-v0: DQN e DDQN com demonstrações

No MountainCar-v0, DQN e DDQN utilizaram MLP $2 \to 128 \to 128 \to 3$, com posição e velocidade normalizadas, em três sementes (11, 22 e 33).

Tentativas iniciais sem demonstrações não alcançaram o objetivo (-200), mas não constituíram um controle completo e, portanto, não foram incluídas na comparação quantitativa.

Tabela 6: Parâmetros dos treinamentos profundos DQN e DDQN no CartPole-v1.

Parâmetro	**Configuração**
Arquitetura	$4 \rightarrow 128 \rightarrow 128 \rightarrow 2$
Parâmetros por rede	17.410
Episódios por treinamento	600
Sementes	11, 22 e 33
Taxa de aprendizado	0,001
Fator de desconto (γ)	0,99
Exploração inicial e mínima	1,0 e 0,05
Decaimento de exploração A	35.000 interações
Decaimento de exploração B	15.000 interações
Capacidade do *replay buffer*	50.000 transições
Amostras mínimas para iniciar	1.000 transições
Tamanho do minibatch	64
Frequência de otimização	A cada 4 interações
Sincronização da rede-alvo	A cada 500 interações
Avaliação periódica	A cada 50 episódios
Partidas por avaliação periódica	20
Partidas por avaliação final	100

Tabela 7: Configuração de treinamento de DQN e DDQN no MountainCar-v0 com experiências demonstrativas.

Parâmetro	**Valor**
Algoritmos	DQN e DDQN
Arquitetura MLP	$2 \rightarrow 128 \rightarrow 128 \rightarrow 3$
Episódios por treinamento	1.200
Sementes	11, 22 e 33
Taxa de aprendizado	0,0005
Fator de desconto (γ)	0,99
Exploração ε	$1{,}0 \rightarrow 0{,}05$
Decaimento de ε	120.000 interações
Capacidade do *replay buffer* do agente	100.000 transições
Demonstrações geradas	80 trajetórias; 9.565 transições
Proporção das demonstrações por minibatch	25%
Tamanho do minibatch	64
Frequência de otimização	4 interações
Atualização da rede-alvo	1.000 interações
Avaliação periódica	100 episódios
Partidas por avaliação periódica	50
Partidas por avaliação final	100
Limite de passos por partida	200

3.1.8 Space Invaders-v5: DQN e DDQN

Foram realizados dois treinamentos independentes, um com DQN e outro com DDQN, utilizando a mesma semente (33) e um orçamento de 1.000.000 de decisões por algoritmo. A implementação em PyTorch foi executada em GPU NVIDIA Tesla T4, com a mesma arquitetura convolucional e os mesmos hiperparâmetros para ambos os métodos. As configurações principais constam na Tabela 8.

Tabela 8: Configuração de treinamento no Space Invaders-v5.

Parâmetro	**Valor**
Algoritmos e semente	DQN, DDQN; 33
Decisões por algoritmo	1.000.000
Observações	4 quadros de 84×84 pixels, escala de cinza
Arquitetura	CNN, 3 camadas convolucionais e camada densa de 512 unidades
Parâmetros treináveis	1.687.206 por rede
Taxa de aprendizado; fator de desconto	10^{-4}; $\gamma = 0{,}99$
Exploração ε-greedy	$1{,}0 \rightarrow 0{,}1$ em 500.000 decisões
Memória de experiências	50.000 transições; início após 20.000 decisões
Minibatch; frequência de otimização	32; a cada 4 decisões
Atualização da rede-alvo	A cada 10.000 decisões
Repetição de quadros; ações persistentes	4; probabilidade de 0,25
Avaliação periódica	A cada 100.000 decisões; 10 partidas
Avaliação final; referência aleatória	30 partidas; 20 partidas

3.1.9 Pong-v5: DQN e DDQN

Foram conduzidos dois treinamentos independentes, com DQN e DDQN, utilizando a mesma semente (33) e **2.000.000 de decisões por algoritmo**. Ambos empregaram a mesma rede convolucional e os mesmos hiperparâmetros, diferindo apenas no cálculo do alvo temporal. A semente foi selecionada após a inspeção de uma rodada preliminar; assim, este experimento constitui uma comparação exploratória, e não uma avaliação estatística entre múltiplas inicializações.

3.2. Procedimentos de Treinamento e Avaliação

3.2.1 FrozenLake-v1

As tabelas Q começaram em zero. A cada 100 episódios, avaliaram-se 50 partidas gulosas, registrando sucesso, retorno, passos e políticas. Cada configuração foi executada uma vez; a semente 123 fixou o ambiente, mas não explicitamente as ações exploratórias, limitando a reprodutibilidade.

3.2.2 Blackjack-v1

As ações foram ε-greedy, com desempate aleatório entre máximos de Q. A cada 10.000 episódios, realizaram-se 2.000 partidas gulosas e, ao final, 10.000 por semente. Mediram-se

Tabela 9: Configuração experimental de DQN e DDQN no Pong-v5.

Parâmetro	**Configuração**
Algoritmos e semente	DQN, DDQN; 33
Decisões por algoritmo	2.000.000
Dispositivo	GPU NVIDIA Tesla T4
Observações	4 quadros de 84×84 pixels, em cinza
Ações disponíveis	FIRE, RIGHTFIRE e LEFTFIRE (3 ações)
Arquitetura	CNN de 3 convoluções, camada densa de 512 unidades; 1.685.667 parâmetros por rede
Taxa de aprendizado e desconto	10^{-4}; $\gamma = 0{,}99$
Exploração ε-greedy	$1{,}0 \rightarrow 0{,}1$ em 150.000 decisões
Memória de experiências	20.000 transições; início após 10.000 decisões
Minibatch e otimização	32; atualização a cada 4 decisões
Sincronização da rede-alvo	A cada 10.000 decisões
Repetição de quadros e ações persistentes	4; probabilidade de 0,25
Avaliação periódica	A cada 100.000 decisões; 10 partidas
Avaliação final	30 partidas por algoritmo
Limite de decisões por episódio	5.000

recompensa, vitórias, empates e derrotas, com agregação entre sementes.

Três referências sem aprendizado foram avaliadas em 10.000 partidas cada: ações aleatórias, parar em 17 e parar em 18 pontos. Visualizaram-se as políticas da semente 11 segundo o uso de ás; empates de valor Q na avaliação foram decididos aleatoriamente.

3.2.3 CliffWalking-v1

Registraram-se recompensa, passos, quedas e chegada após cada transição. Ao final, cada política foi avaliada em 300 episódios gulosos ($\varepsilon = 0$) e exploratórios ($\varepsilon = 0{,}1$), sem treinamento adicional. O limite de 200 passos foi considerado insucesso sem chegada; resultados agregaram recompensa, sucesso, duração e quedas entre sementes.

As curvas utilizaram média móvel de 100 episódios, e trajetórias malsucedidas foram inspecionadas. Os horizontes de 3.000 e 6.000 episódios constituem treinamentos independentes.

3.2.4 Taxi-v4

No Taxi-v4, os agentes compartilharam estados iniciais por semente e episódio, mas tiveram geradores exploratórios próprios; não se usaram máscaras. A cada 2.000 episódios, avaliaram-se 500 partidas; ao final, 3.000 por semente, em estados comparáveis. Mediram-se recompensa, entregas, passos, penalidades e truncamentos, com média móvel de 500 episódios e agregação entre sementes.

Uma entrega da semente 11, com estado inicial comum, serviu apenas de visualização qualitativa.

3.2.5 CartPole-v1

Usou-se `numpy.digitize` na discretização, seguido de política ε-greedy. A falha física elimina o *bootstrap*; truncamentos preservam-no, sem ultrapassar 500 passos.

A cada 1.500 episódios, avaliaram-se 100 partidas gulosas e, ao final, 200 por semente, com inicializações comuns e agente aleatório de referência. Mediram-se retorno, duração e proporções acima de 475 ou exatamente 500 passos. As curvas usaram média móvel de 200 episódios. O limiar de 475 é operacional, não uma prova de convergência.

3.2.6 CartPole-v1: DQN e DDQN

DQN e DDQN receberam diretamente quatro observações, treinaram com experiências armazenadas e diferiram apenas no alvo temporal. A atualização omitiu o *bootstrap* nas terminações físicas e o manteve nos truncamentos.

Realizaram-se avaliações gulosas a cada 50 episódios (20 partidas) e ao final (100 por semente), com estados iniciais fixos, avaliando retorno e frequência de episódios de 475 e 500 passos. Usou-se média móvel de 30 episódios. O orçamento de 600 episódios não igualou o número de interações entre agentes; avaliaram-se os modelos finais.

3.2.7 MountainCar-v0: treinamento, demonstrações e avaliação

Uma política baseada no sinal da velocidade gerou 80 trajetórias bem-sucedidas, com 9.565 transições (média de 119,56 passos), reunidas em memória auxiliar. Cada minibatch continha 48 experiências do agente e 16 demonstrações (25%). Não houve pré-treinamento supervisionado nem modificação nas recompensas.

Aplicaram-se Adam, perda de Huber, norma do gradiente limitada a 10 e rede-alvo periódica. O *bootstrap* foi anulado apenas em terminações reais. A cada 100 episódios, avaliaram-se 50 partidas e, ao final, 100 por semente, medindo retorno, sucesso, posição máxima e passos das partidas bem-sucedidas. Os resultados foram agregados entre sementes e curvas de treinamento suavizadas em 100 episódios. As demonstrações são experiências externas ao orçamento do agente.

3.2.8 Space Invaders-v5: treinamento e avaliação

As imagens foram pré-processadas em escala de cinza e empilhadas em sequências de quatro quadros. Durante o treinamento, as recompensas foram limitadas ao intervalo $[-1, 1]$ para atualização da rede, utilizando Adam e perda de Huber; as pontuações brutas foram preservadas nas avaliações. Episódios tiveram limite de 5.000 decisões, e a política gulosa foi avaliada a cada 100.000 decisões em dez partidas com inicializações fixas. Ao final, os modelos da última etapa de treinamento, e não os melhores checkpoints intermediários, foram testados em 30 partidas por algoritmo, utilizando as mesmas sementes de avaliação. Uma política aleatória foi avaliada separadamente em 20 partidas. A comparação entre algoritmos é descritiva, pois houve apenas uma semente de treinamento por método.

3.2.9 Pong-v5: treinamento e avaliação

As imagens foram convertidas para escala de cinza, redimensionadas para 84×84 pixels e empilhadas em grupos de quatro quadros. Empregaram-se Adam, perda de Huber e limitação da norma do gradiente em 10, preservando-se a recompensa original do ambiente. As avaliações periódicas utilizaram políticas gulosas em dez partidas com sementes fixas; ao final, os modelos da última etapa foram avaliados em 30 partidas independentes das avaliações periódicas, com as mesmas sementes para DQN e DDQN. Registraram-se recompensa média, pontos marcados e sofridos, vitórias, truncamentos e duração das partidas.

4. Resultados

4.1. Resultados: FrozenLake-v1

Todas as quatro configurações alcançaram o objetivo na avaliação final, mas divergiram na evolução da aprendizagem, conforme a Tabela 10.

Tabela 10: Resultados dos quatro experimentos no FrozenLake-v1.

Indicador	**Q-L 5k**	**Q-L 10k**	**SARSA 5k**	**SARSA 10k**
Sucessos no treinamento	3.240	7.004	3.183	6.708
Sucesso médio no treinamento	64,80%	70,04%	63,66%	67,08%
Sucesso nos últimos 100 episódios	89%	87%	90%	95%
Primeira avaliação com 100%	700	600	900	1.400
Avaliações com 100%	44/50	95/100	34/50	65/100
Avaliações com 0%	3/50	2/100	11/50	28/100
Média das avaliações	88,32%	95,22%	68,32%	65,44%
Média das últimas 10 avaliações	100%	100%	70%	90%
Avaliação final	100%	100%	100%	100%
Passos totais	74.717	155.478	77.293	159.347
Passos da demonstração final	14	14	14	14

4.1.1 Desempenho durante o treinamento

A Figura 1 compara a taxa de sucesso a cada 100 episódios.

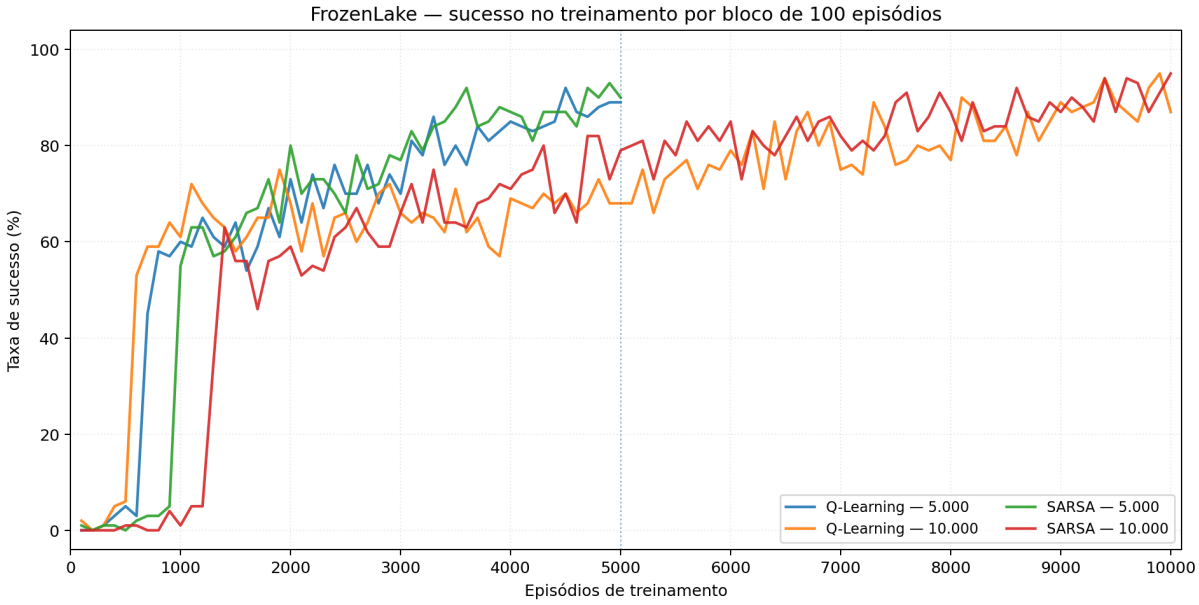


Figura 1: Evolução das taxas de sucesso durante o treinamento dos algoritmos Q-Learning(0) e SARSA(0), considerando 5.000 e 10.000 episódios. Cada ponto representa a proporção de episódios bem-sucedidos no respectivo bloco de 100 episódios.

As taxas médias de sucesso no treinamento do Q-Learning/SARSA foram 64,80%/63,66% com 5.000 episódios e 70,04%/67,08% com 10.000. Na rodada prolongada, as taxas aumentaram da primeira para a segunda metade: 58,84% para 81,24% no Q-Learning e 49,42% para 84,74% no SARSA. Nos últimos 100 episódios, o SARSA obteve 95% contra 87% do Q-Learning. Como o decaimento da exploração também mudou, não é possível isolar o efeito do horizonte.

4.1.2 Avaliação das políticas aprendidas

A Figura 2 mostra as avaliações a cada 100 episódios.

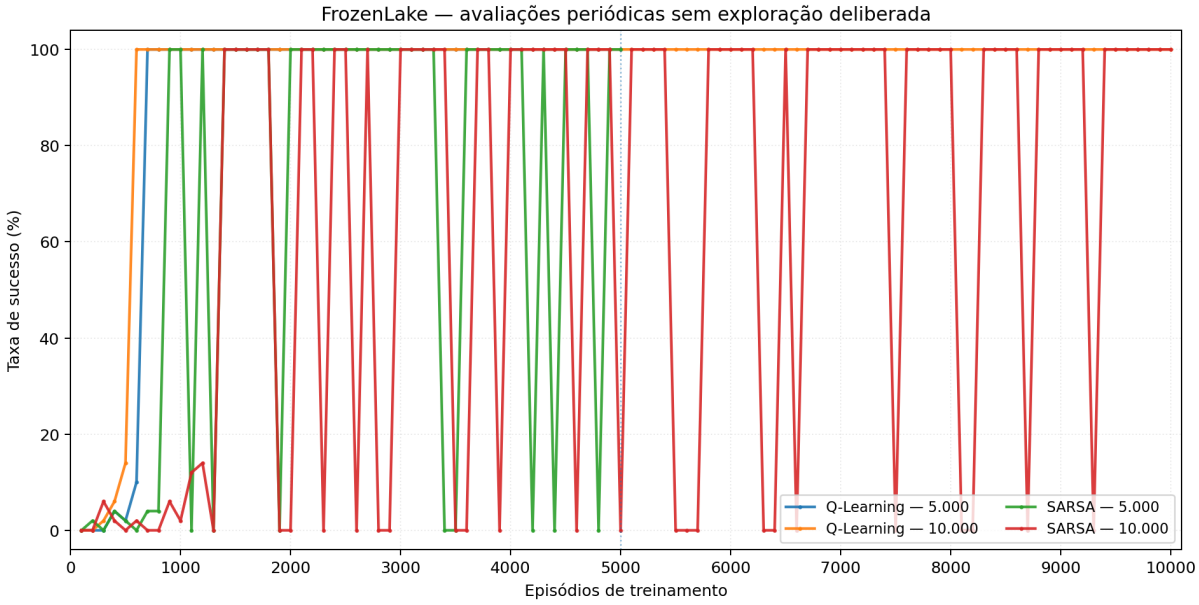


Figura 2: Comparação das taxas de sucesso nas avaliações periódicas dos algoritmos Q-Learning(0) e SARSA(0). Cada avaliação corresponde a 50 episódios executados sem exploração deliberada.

O Q-Learning atingiu a primeira avaliação perfeita após 700 episódios (5k) e 600 (10k), embora avaliações posteriores tenham apresentado quedas (Tabela 10).

O SARSA alcançou a primeira avaliação de 100% após 900 episódios (rodada de 5.000) e 1.400 (rodada de 10.000), mas manteve oscilações: na rodada prolongada, houve 28 avaliações nulas e 65 completas. Nas dez últimas avaliações, sua média passou de 70% (5.000) para 90% (10.000), enquanto o Q-Learning manteve 100% em ambas as rodadas.

4.1.3 Políticas finais aprendidas

Nas demonstrações finais, ambos os algoritmos chegaram ao objetivo em 14 movimentos, distância mínima ortogonal entre cantos opostos da grade 8×8. As Figuras 3 e 4 revelam, contudo, ações preferenciais e tabelas Q diferentes.

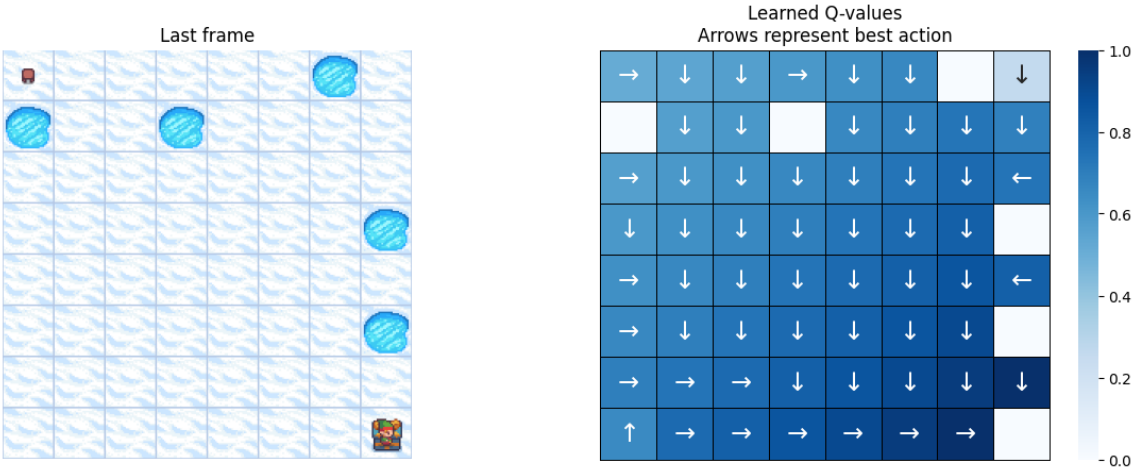


Figura 3: Representação dos valores máximos de ação e da política aprendida pelo Q-Learning(0) após 10.000 episódios no FrozenLake-v1.

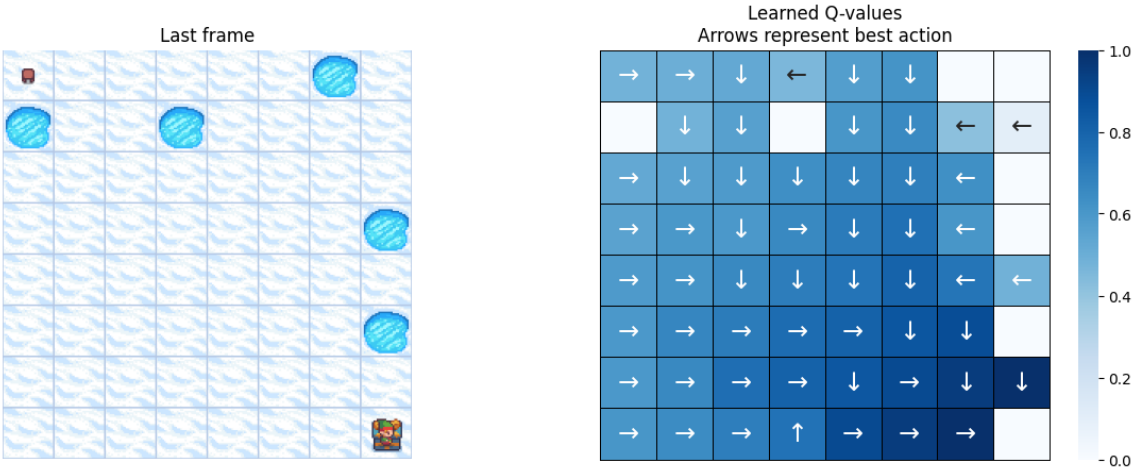


Figura 4: Representação dos valores máximos de ação e da política aprendida pelo SARSA(0) após 10.000 episódios no FrozenLake-v1.

4.2. Resultados: Blackjack-v1

4.2.1 Desempenho final dos algoritmos

Na avaliação final, SARSA(0) e Q-Learning(0) obtiveram resultados próximos: 42,67% e 42,59% de vitórias, com recompensas médias $-0{,}0528$ e $-0{,}0579$, respectivamente; as diferenças foram pequenas em relação à dispersão entre sementes (Tabela 11).

4.2.2 Evolução do desempenho

Nas avaliações periódicas, recompensa e vitórias oscilaram, sem tendência monotônica nem separação consistente entre métodos (Figuras 5 e 6); as faixas indicam um desvio-padrão entre sementes.

Tabela 11: Desempenho final no Blackjack-v1: média e desvio-padrão entre três sementes.

Indicador	**Q-Learning(0)**	**SARSA(0)**
Vitórias médias (%)	42,5867	42,6700
Desvio-padrão de vitórias (p.p.)	0,1266	0,3915
Empates médios (%)	9,0400	9,3833
Derrotas médias (%)	48,3733	47,9467
Recompensa média	−0,0579	−0,0528
Desvio-padrão da recompensa	0,0052	0,0078

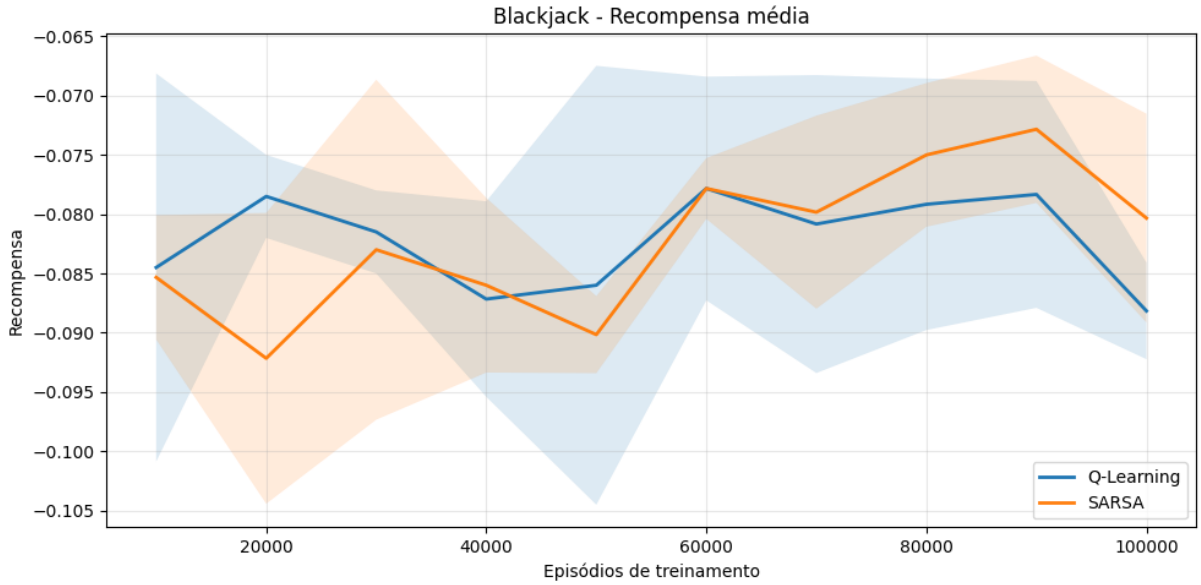


Figura 5: Recompensa média nas avaliações periódicas de Q-Learning(0) e SARSA(0) no Blackjack-v1, em intervalos de 10.000 episódios. As regiões sombreadas representam um desvio-padrão entre três sementes.

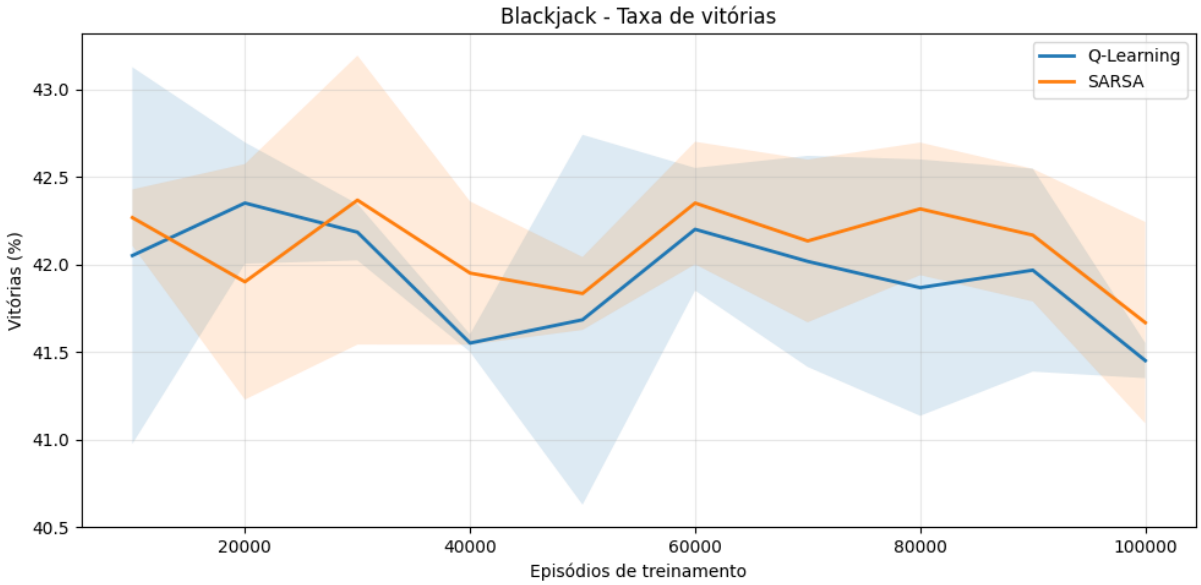


Figura 6: Taxa de vitórias nas avaliações periódicas dos algoritmos no Blackjack-v1, com média e desvio-padrão entre três sementes.

4.2.3 Análise das políticas aprendidas

Os mapas das políticas da semente 11 distinguem estados com e sem ás utilizável (Figura 7). Ambos tendem a parar com somas elevadas, mas divergem em decisões locais segundo a carta do dealer. Células sem preferência numérica não permitem inferir visitação.

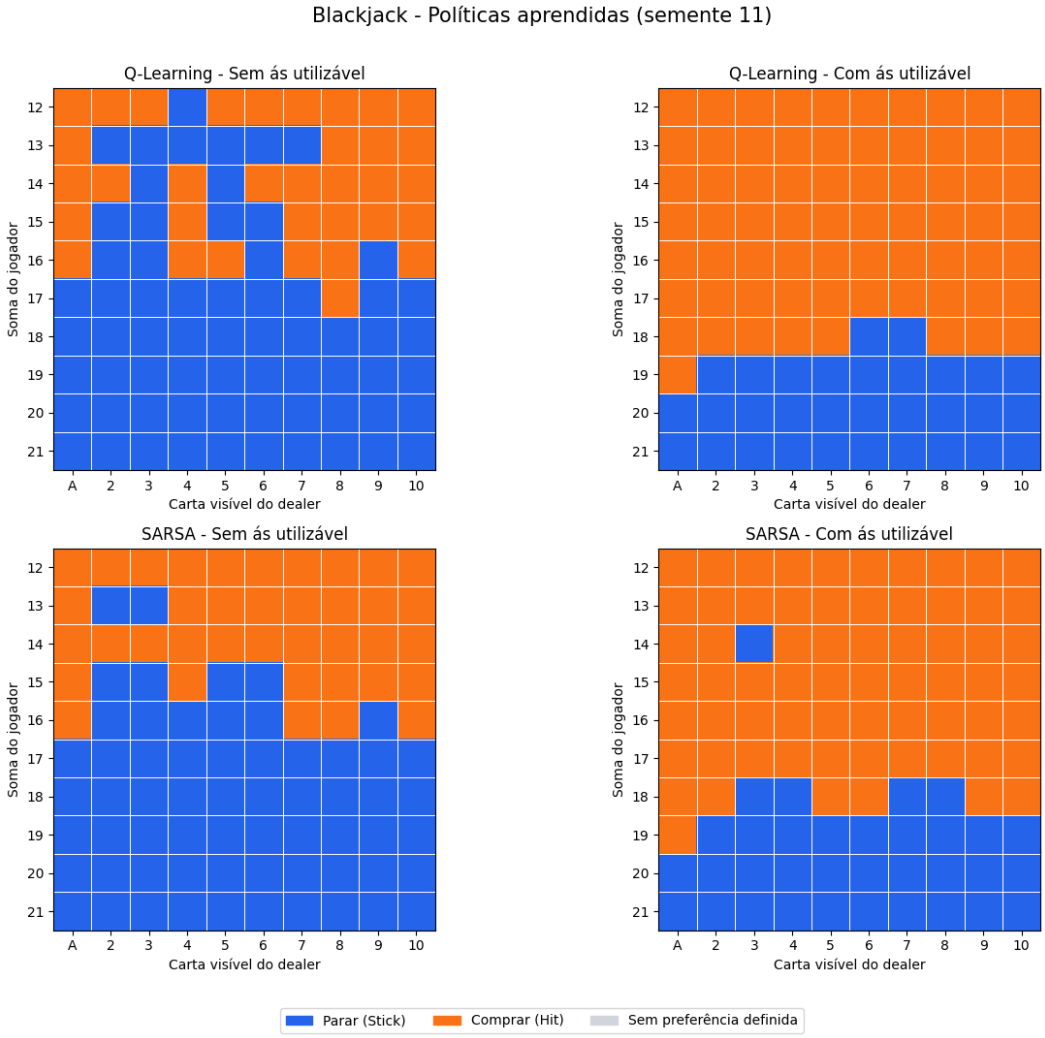


Figura 7: Políticas tabulares de Q-Learning(0) e SARSA(0) na semente 11. Azul: parar; laranja: comprar; cinza: sem preferência numérica definida. Os estados são agrupados conforme a presença de ás utilizável.

4.2.4 Comparação com estratégias de referência

Contra referências sem aprendizado (Tabela 12), as políticas treinadas ganharam cerca de 14,3 pontos percentuais em vitórias frente à ação aleatória e aproximadamente 1,2 ponto frente à regra de parar em 17.

Tabela 12: Desempenho das políticas aprendidas e das estratégias de referência no Blackjack-v1.

Estratégia	Vitórias (%)	Empates (%)	Derrotas (%)	Recompensa média
Aleatória	28,32	4,22	67,46	−0,3914
Parar em 17	41,41	10,31	48,28	−0,0687
Parar em 18	40,80	8,89	50,31	−0,0951
Q-Learning(0)	42,59	9,04	48,37	−0,0579
SARSA(0)	42,67	9,38	47,95	−0,0528

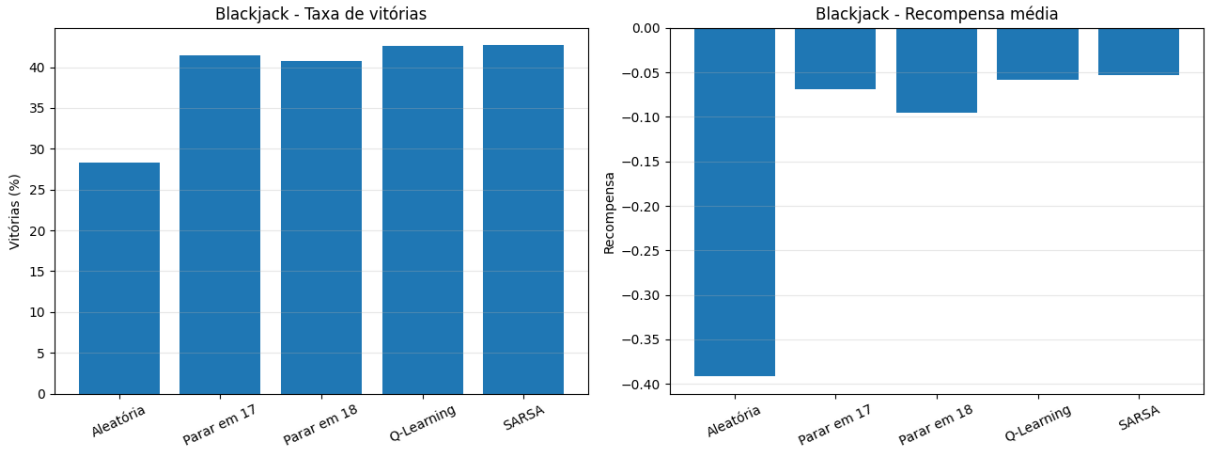


Figura 8: Comparação da taxa de vitórias e da recompensa média dos dois agentes treinados com três estratégias sem aprendizado.

4.3. Resultados: CliffWalking-v1

As políticas foram avaliadas sem exploração e com $\varepsilon = 0{,}1$, distinguindo menor percurso de exposição ao precipício (Tabelas 13 e 15).

4.3.1 Avaliação das políticas gulosas

Tabela 13: Avaliação gulosa ($\varepsilon = 0$) no CliffWalking-v1: médias entre três sementes.

Indicador	Q-L 3k	Q-L 6k	SARSA 3k	SARSA 6k
Recompensa média	−13,00	−13,00	−78,00	−78,00
Desvio-padrão da recompensa	0,00	0,00	105,66	105,66
Taxa de sucesso (%)	100,00	100,00	66,67	66,67
Passos médios	13,00	13,00	78,00	78,00
Quedas médias	0,000	0,000	0,000	0,000

Na avaliação gulosa, Q-Learning(0) obteve 100% de sucesso com trajetórias mínimas de 13 passos nas três sementes. SARSA(0) alcançou 66,67%: duas sementes concluíram em 17 passos e uma esgotou o limite de 200.

Tabela 14: Resultados individuais das políticas gulosas do SARSA(0) no CliffWalking-v1.

Semente	**3.000 episódios**		**6.000 episódios**	
	Retorno	**Sucesso (%)**	**Retorno**	**Sucesso (%)**
11	−17	100	−17	100
22	−200	0	−17	100
33	−17	100	−200	0

Tabela 15: Avaliação exploratória ($\varepsilon = 0{,}1$) no CliffWalking-v1: médias entre três sementes.

Indicador	**Q-L 3k**	**Q-L 6k**	**SARSA 3k**	**SARSA 6k**
Recompensa média	−47,140	−47,294	−56,034	−34,633
Desvio-padrão da recompensa	1,372	1,330	57,738	21,126
Taxa de sucesso (%)	100,000	100,000	94,222	99,889
Passos médios	16,780	16,714	52,404	31,773
Quedas médias	0,307	0,309	0,037	0,029
Episódios com queda (%)	23,222	23,778	3,556	2,889

4.3.2 Avaliação com exploração mantida

Com exploração, o Q-Learning manteve sucesso completo, mas caiu em cerca de 23–24% dos episódios. O SARSA reduziu as quedas de 3,556% (3k) para 2,889% (6k).

Após 6.000 episódios, a recompensa exploratória média do SARSA melhorou de −56,034 para −34,633, e o sucesso de 94,222% para 99,889%. A variação não foi uniforme: a semente 22 passou de −122,703 para −22,620, enquanto a 33 piorou de −23,027 para −59,027.

4.3.3 Evolução durante o treinamento e políticas aprendidas

As curvas de 6.000 episódios (Figuras 9 e 10) mostram menos quedas e retornos geralmente superiores no treinamento do SARSA, apesar da eficácia final das políticas gulosas do Q-Learning.

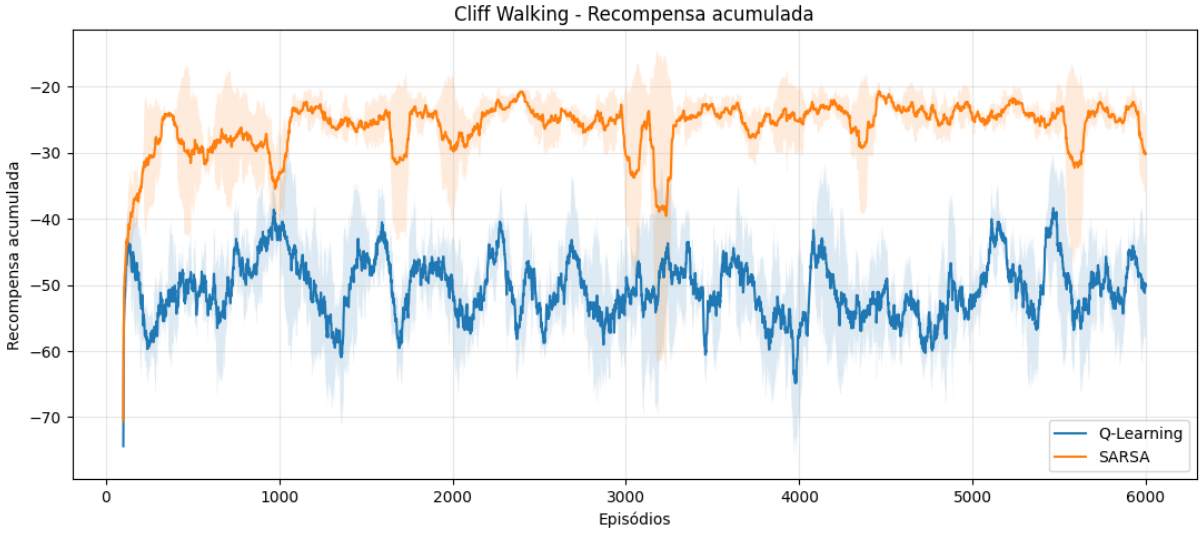


Figura 9: Recompensa acumulada no treinamento com 6.000 episódios no CliffWalking-v1, representada por média móvel de 100 episódios e agregação entre as três sementes.

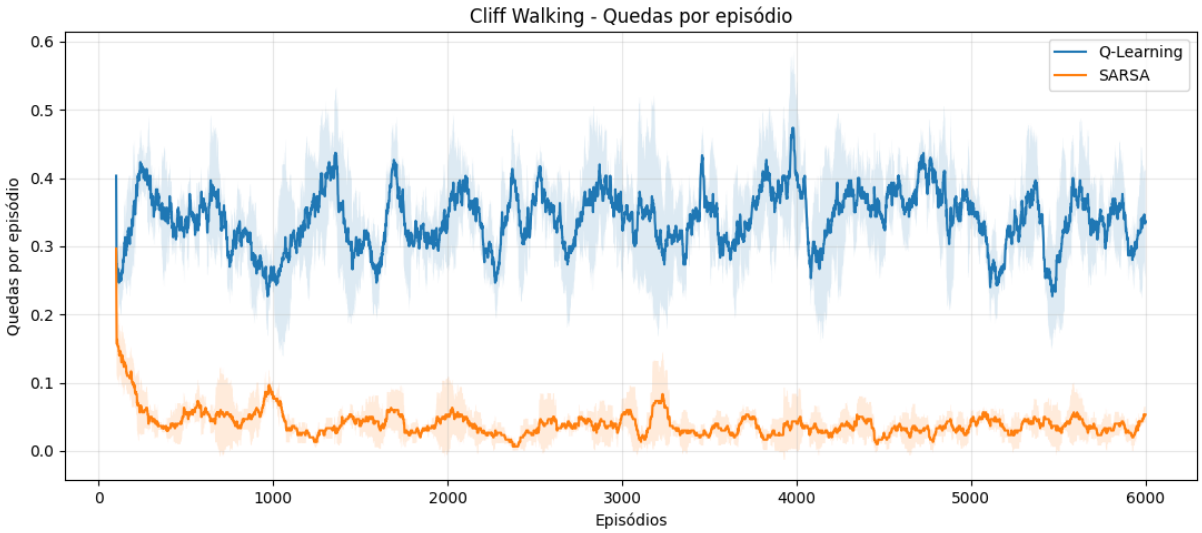


Figura 10: Quantidade média de quedas no precipício durante o treinamento com 6.000 episódios, utilizando média móvel de 100 episódios e três sementes.

Os mapas (Figuras 11 e 12) mostram rotas mínimas do Q-Learning próximas ao precipício e trajetórias SARSA mais afastadas, sem que os exemplos individuais representem todas as execuções.



Figura 11: Mapas das políticas aprendidas após 6.000 episódios, semente 22, com setas representando ações preferenciais e cores representando o maior valor Q por estado.

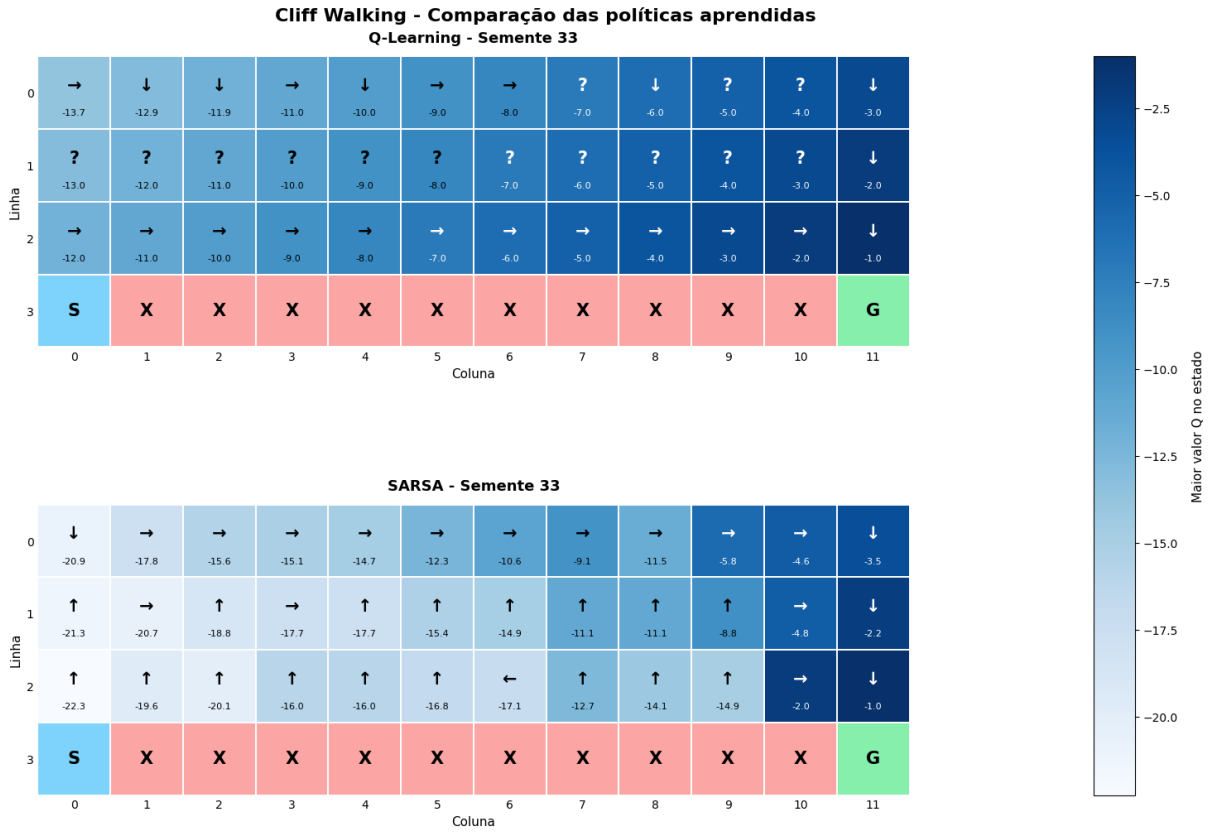


Figura 12: Mapas das políticas aprendidas após 6.000 episódios, semente 33. A política SARSA(0) apresenta um comportamento cíclico nos estados 0 e 12.

4.3.4 Diagnóstico das políticas SARSA malsucedidas

Na semente 22 com 3.000 episódios, o SARSA percorreu $36 \to 24 \to 12 \to 0$ e passou a tentar subir na borda superior. No estado 0, essa ação tinha valor $Q = -25{,}7581$, pouco acima de mover à direita ($-25{,}8155$); o episódio terminou após 200 passos, sem queda ou sucesso.

Com 6.000 episódios, a semente 22 concluiu a tarefa em 17 passos, mas a semente 33 passou a oscilar entre os estados 0 e 12, visitados 99 vezes cada, com retorno -200.

4.4. Resultados: Taxi-v4

4.4.1 Desempenho final dos agentes

Após 20.000 episódios, ambas as abordagens completaram 100% das 9.000 partidas finais por algoritmo, com recompensa média +7,949, 13,051 passos médios e nenhuma penalidade de -10 ou truncamento (Tabela 16).

Nas entregas sem erro, $R = 20 - (n - 1) = 21 - n$; logo, 13,051 passos correspondem a retorno médio 7,949. O desvio-padrão nulo das médias entre sementes não implica tabelas Q iguais nem partidas idênticas.

Tabela 16: Resultados finais de Q-Learning(0) e SARSA(0) no Taxi-v4: médias entre três sementes.

Indicador	**Q-Learning(0)**	**SARSA(0)**
Entregas concluídas (%)	100,00	100,00
Recompensa média	+7,949	+7,949
Desvio-padrão entre sementes	0,000	0,000
Passos médios por episódio	13,051	13,051
Penalidades de −10 por episódio	0,000	0,000
Episódios truncados (%)	0,00	0,00

4.4.2 Velocidade de aprendizagem e evolução do desempenho

A evolução das entregas nas avaliações periódicas está na Tabela 17.

Tabela 17: Evolução da taxa de sucesso nas avaliações periódicas do Taxi-v4.

Episódios de treinamento	**Q-Learning (%)**	**SARSA (%)**
2.000	98,20	9,47
4.000	100,00	34,80
8.000	100,00	78,33
10.000	100,00	94,07
12.000	100,00	98,47
14.000	100,00	99,80
16.000	100,00	100,00
20.000	100,00	100,00

O Q-Learning atingiu 98,20% de sucesso após 2.000 episódios e 100% após 4.000; o SARSA partiu de 9,47%, alcançou 94,07% em 10.000 e 100% em 16.000. Assim, o Q-Learning atingiu primeiro o patamar máximo observado, sob este protocolo.

As Figuras 13 e 14 mostram o início mais lento do SARSA e a equivalência nas avaliações finais.

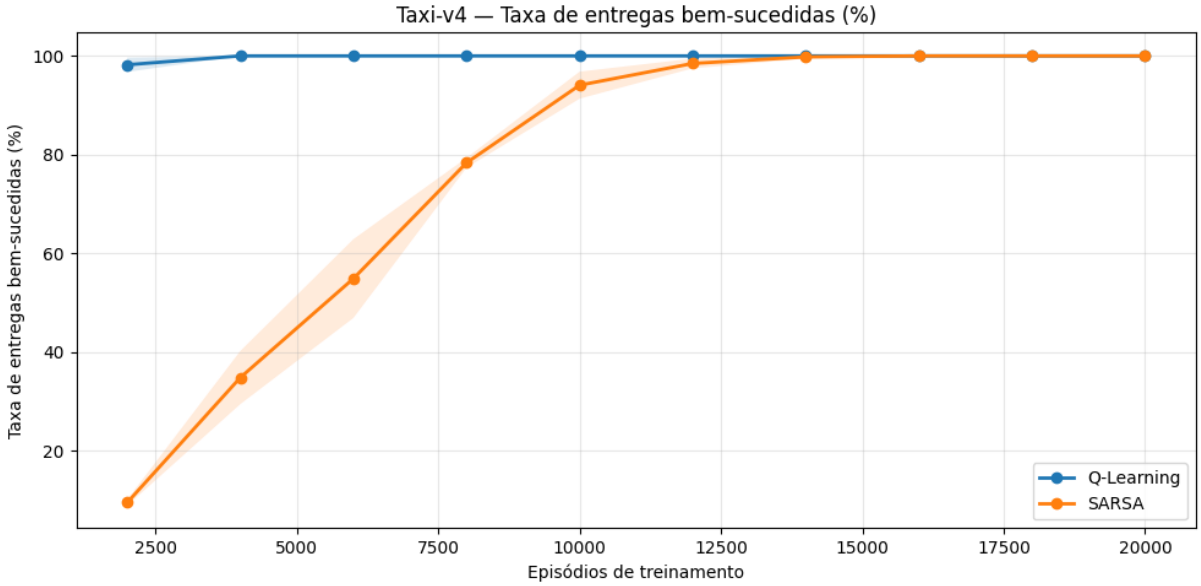


Figura 13: Taxa de entregas concluídas nas avaliações periódicas de Q-Learning(0) e SARSA(0) no Taxi-v4, com média e desvio-padrão entre três sementes.

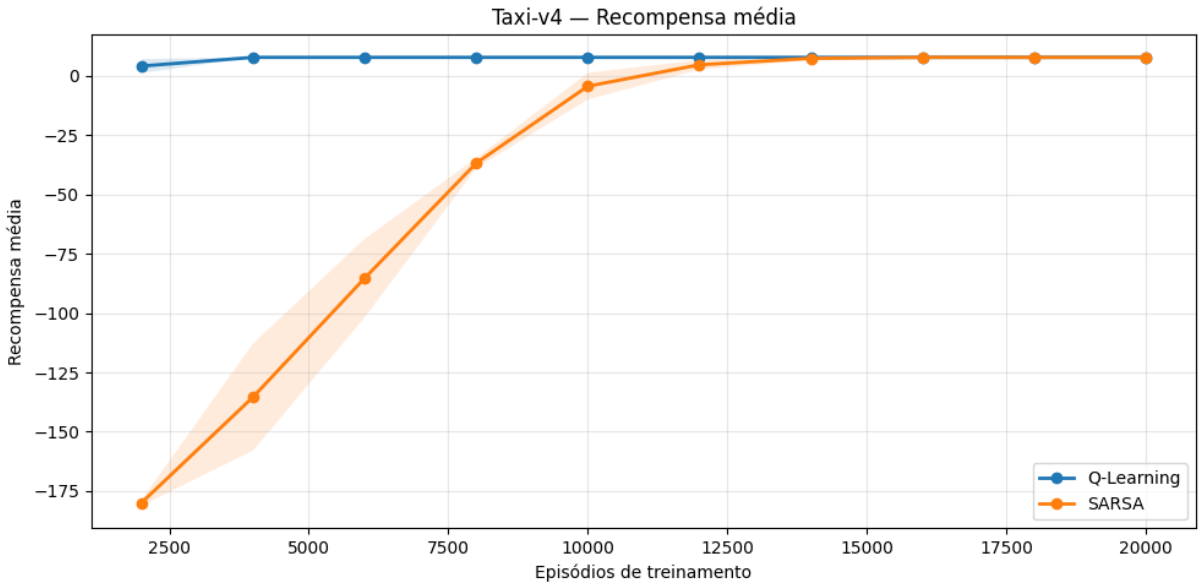


Figura 14: Evolução da recompensa média nas avaliações periódicas, realizadas a cada 2.000 episódios com 500 partidas por semente.

As penalidades de embarque/desembarque indevido, apresentadas na Figura 15, foram eliminadas na avaliação final dos dois agentes.

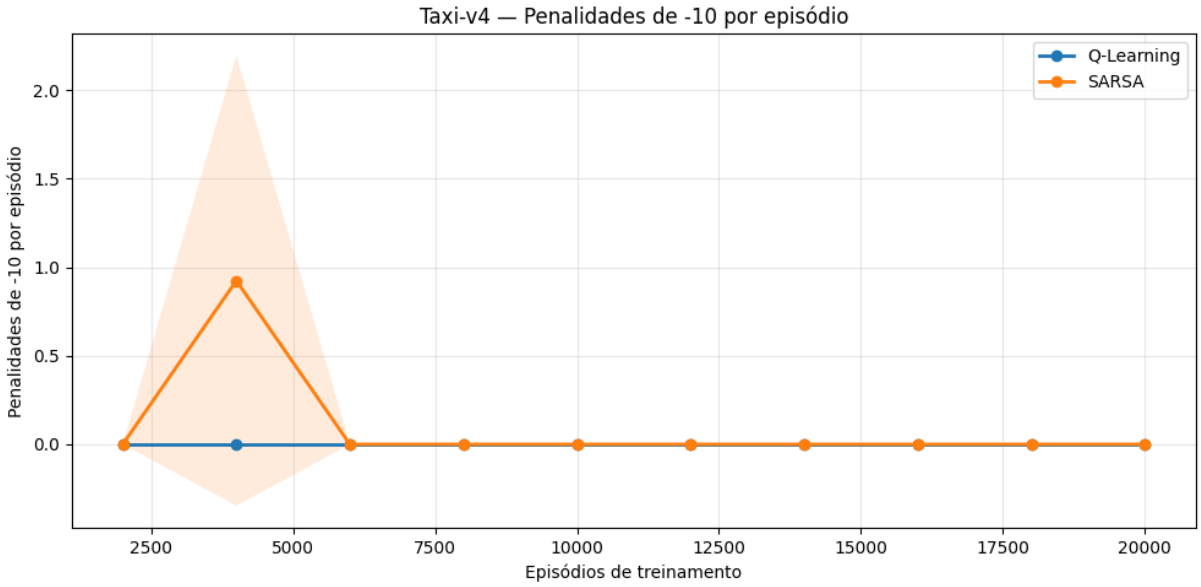


Figura 15: Penalidades médias de −10 nas avaliações periódicas dos agentes no Taxi-v4.

4.4.3 Visualização qualitativa de uma entrega

Na demonstração da semente 11 (Figura 16), os agentes seguiram trajetórias distintas, mas concluíram a entrega em dez ações e retorno +11.

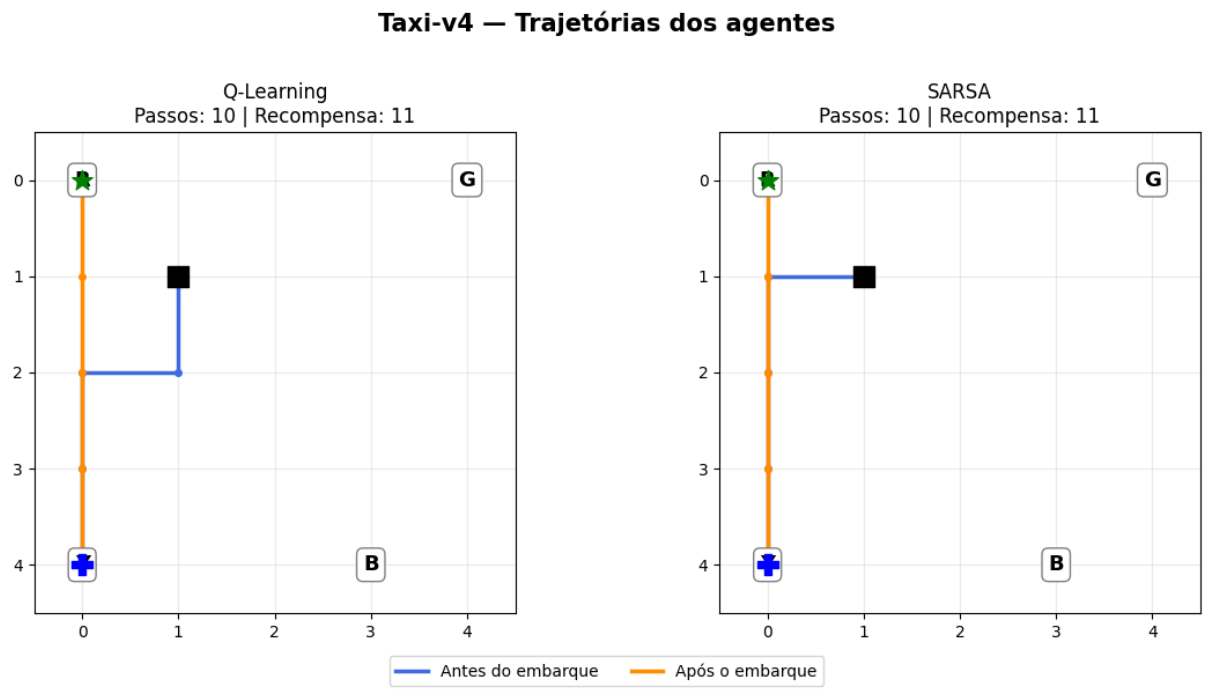


Figura 16: Trajetórias de uma entrega demonstrativa no Taxi-v4. Azul: deslocamento anterior ao embarque; laranja: deslocamento posterior ao embarque. A grade esquemática não representa as paredes internas do ambiente.

Essa partida ilustra apenas um estado inicial e não implica identidade das tabelas Q; as estatísticas agregadas abrangem 9.000 partidas por algoritmo.

4.5. Resultados: CartPole-v1

4.5.1 Comparação entre as discretizações

O CartPole tabular superou a referência aleatória (22,41 pontos); os resultados finais, apresentados na Tabela 18, variaram conforme a discretização e a semente.

Tabela 18: Resultados finais do CartPole-v1: médias e desvios-padrão entre três sementes.

Indicador	**Q-L A**	**Q-L B**	**SARSA A**	**SARSA B**
Recompensa média	293,770	389,483	413,127	500,000
Desvio-padrão entre sementes	129,806	143,603	89,245	0,000
Passos médios	293,770	389,483	413,127	500,000
Episódios com ≥ 475 passos (%)	23,500	56,333	43,833	100,000
Episódios com 500 passos (%)	21,333	56,000	41,667	100,000

Da discretização A para B, as recompensas médias passaram de 293,770 para 389,483 no Q-Learning e de 413,127 para 500,000 no SARSA, indicando ganho agregado com maior resolução.

Na configuração B, o SARSA atingiu 500 pontos nas 600 partidas finais; o Q-Learning manteve elevada variação entre sementes.

4.5.2 Variabilidade entre sementes

A Tabela 19 mostra que o refinamento não beneficiou todas as sementes.

Tabela 19: Recompensa média final por algoritmo, semente e discretização no CartPole-v1.

Algoritmo	Semente	A	B
Q-Learning(0)	11	443,190	227,150
Q-Learning(0)	22	229,300	441,365
Q-Learning(0)	33	208,820	499,935
SARSA(0)	11	321,685	500,000
SARSA(0)	22	500,000	500,000
SARSA(0)	33	417,695	500,000

No Q-Learning, a semente 11 piorou de 443,190 para 227,150 pontos, enquanto 22 e 33 melhoraram. No SARSA, B melhorou 11 e 33 e manteve o máximo da semente 22.

4.5.3 Evolução das políticas durante o treinamento

As avaliações periódicas (Figuras 17 e 18) mostram oscilações e perdas de desempenho após avaliações favoráveis.

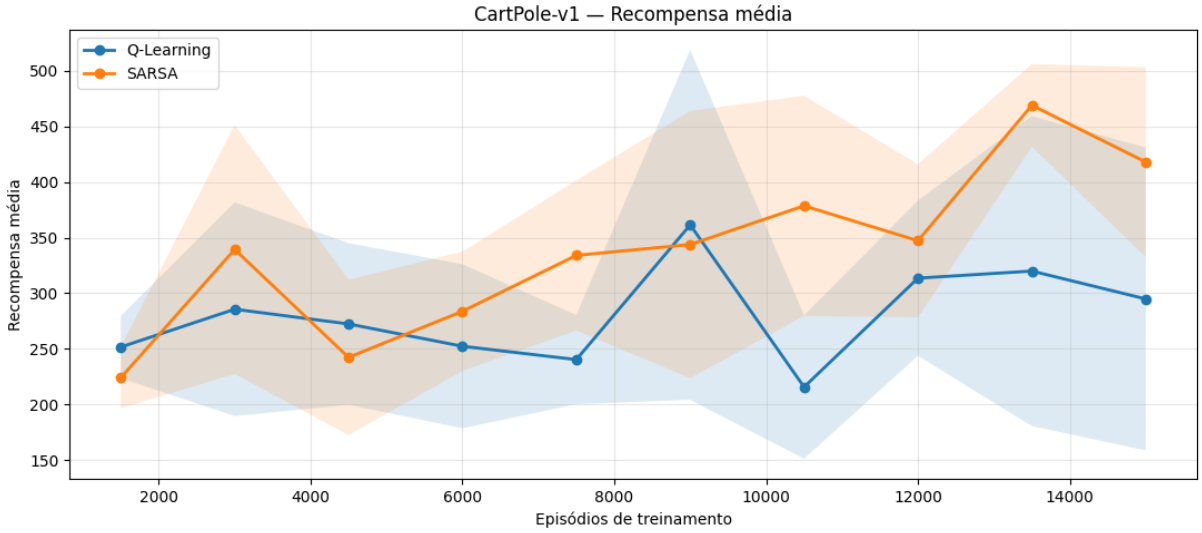


Figura 17: Recompensa média nas avaliações periódicas do CartPole-v1 com discretização A ($6 \times 6 \times 12 \times 12$). As curvas e as faixas representam a média e um desvio-padrão entre três sementes.

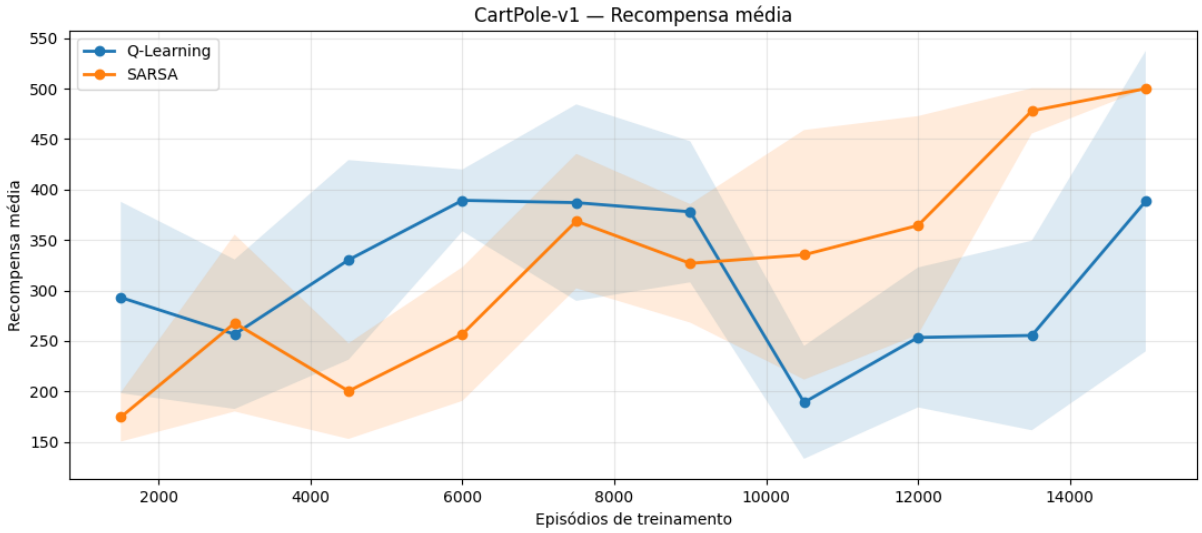


Figura 18: Recompensa média nas avaliações periódicas do CartPole-v1 com discretização B ($8 \times 8 \times 16 \times 16$).

No treinamento com discretização B (Figura 19), o SARSA obteve retornos geralmente maiores na parte final, mas as avaliações gulosas ainda oscilaram.

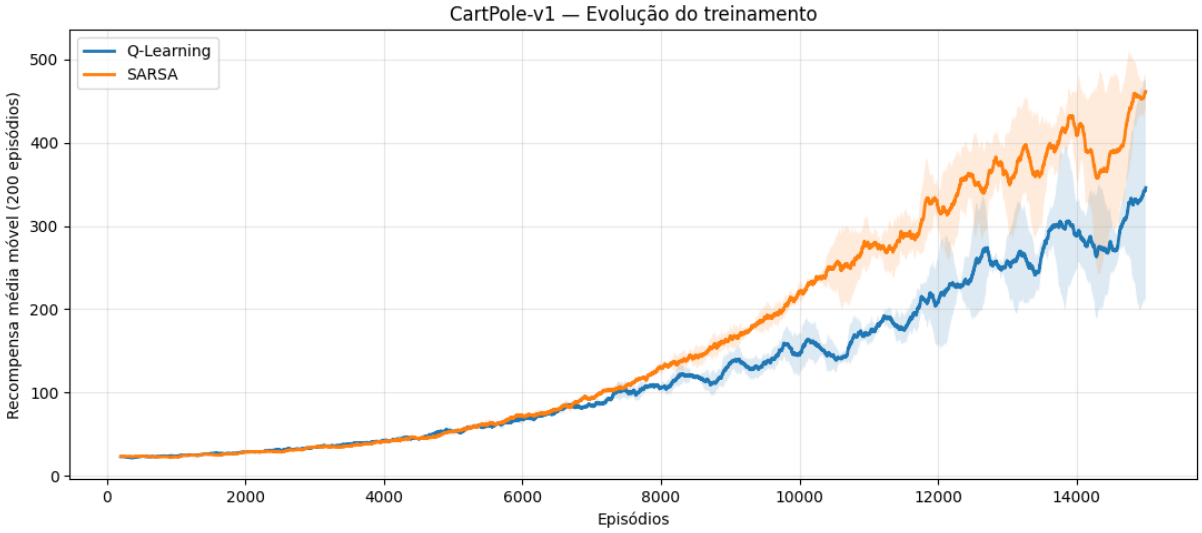


Figura 19: Recompensa média móvel de 200 episódios durante o treinamento com discretização B, agregada entre três sementes.

Na configuração B, o SARSA alcançou 100% de partidas com ao menos 475 passos; o Q-Learning, 56,333% (Figura 20).

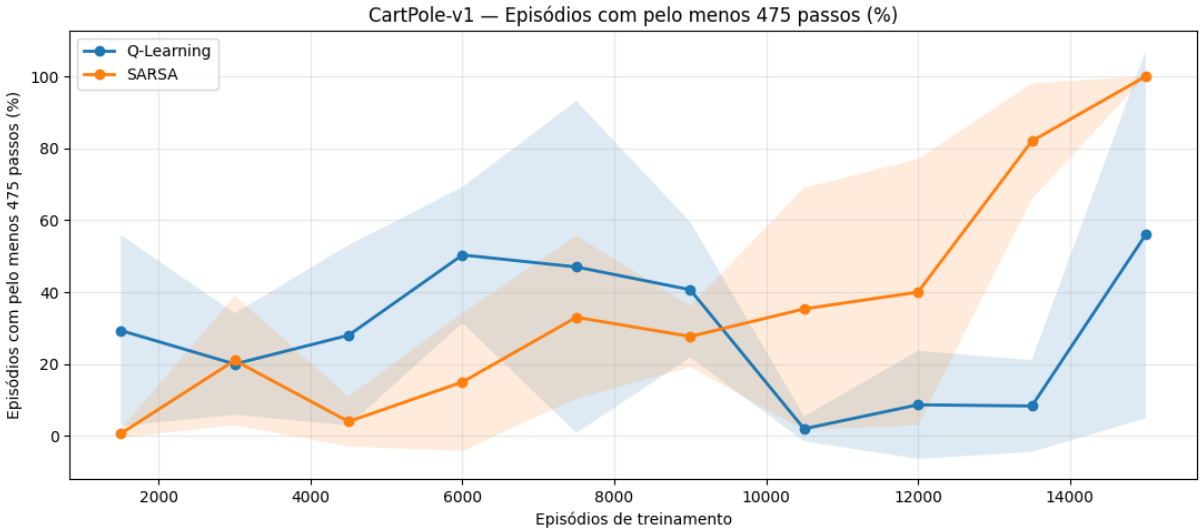


Figura 20: Proporção de partidas de avaliação com pelo menos 475 passos no CartPole-v1, discretização B; média e desvio-padrão entre sementes.

4.6. Resultados: DQN e DDQN no CartPole-v1

4.6.1 Desempenho final nas duas configurações

Nas duas configurações profundas do CartPole, o DQN obteve recompensa média final superior à do DDQN; ambos melhoraram suas médias ao antecipar o decaimento exploratório (Tabela 20).

Tabela 20: Resultados finais de DQN e DDQN no CartPole-v1, com médias entre três sementes.

Indicador	**DQN A**	**DQN B**	**DDQN A**	**DDQN B**
Recompensa média	159,753	276,503	70,177	242,557
Desvio-padrão entre sementes	71,656	117,269	21,379	223,185
Episódios com ≥ 475 passos (%)	0,000	12,000	0,000	33,333
Episódios com 500 passos (%)	0,000	10,667	0,000	33,333

De A para B, as recompensas médias passaram de 159,753 para 276,503 no DQN e de 70,177 para 242,557 no DDQN, mas com elevada variabilidade entre sementes.

4.6.2 Variabilidade entre sementes

A Tabela 21 detalha o resultado por semente. O DQN superou o DDQN em todas as sementes A; em B, o DDQN foi máximo apenas na semente 11.

No DDQN B, os 500 pontos da semente 11 contrastaram com 124,01 e 103,66 nas demais, produzindo desvio-padrão de 223,185. Um resultado perfeito individual não demonstra robustez.

Tabela 21: Recompensa média final de DQN e DDQN por semente e configuração experimental.

Algoritmo	Semente	A: 35.000	B: 15.000
DQN	11	237,72	166,33
DQN	22	96,78	263,41
DQN	33	144,76	399,77
DDQN	11	93,55	500,00
DDQN	22	51,61	124,01
DDQN	33	65,37	103,66

4.6.3 Evolução do desempenho durante os treinamentos

No DDQN A, semente 22, a avaliação periódica caiu de 494,1 pontos (episódio 550) para 48,0 (episódio 600), com 51,61 no teste final independente (Figura 21).

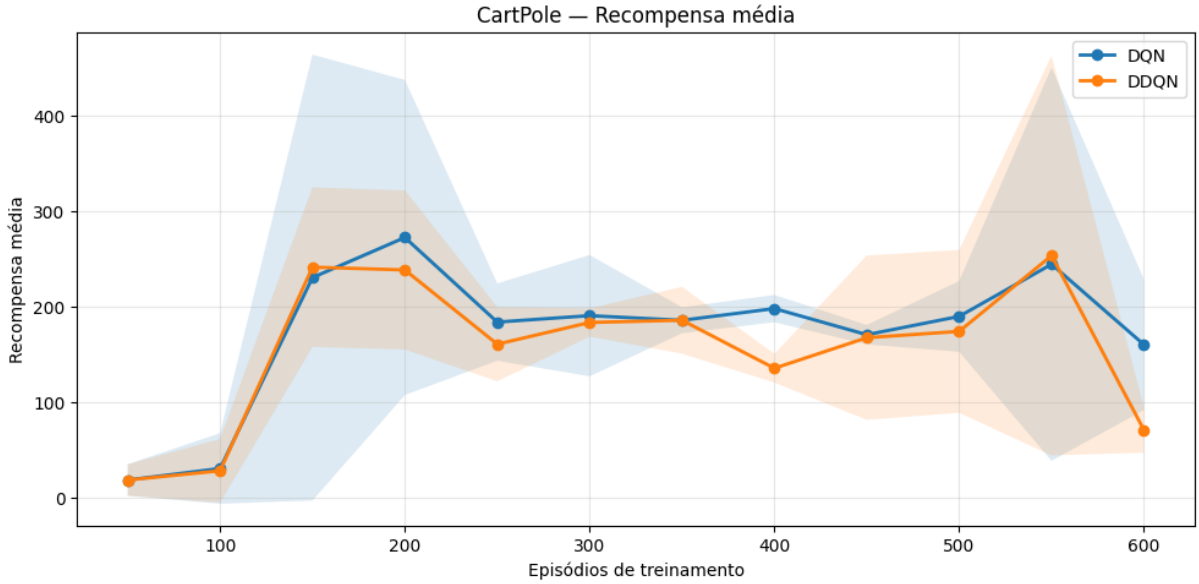


Figura 21: Recompensa média de DQN e DDQN nas avaliações periódicas da configuração A, com decaimento de exploração em 35.000 interações. As faixas representam um desvio-padrão entre as sementes.

Em B, o DDQN 11 terminou em 500, mas DDQN 33 caiu de 414,8 no episódio 350 para 103,66 no teste final; DQN 33 passou de um pico periódico de 500 para 399,77 ao final (Figura 22).

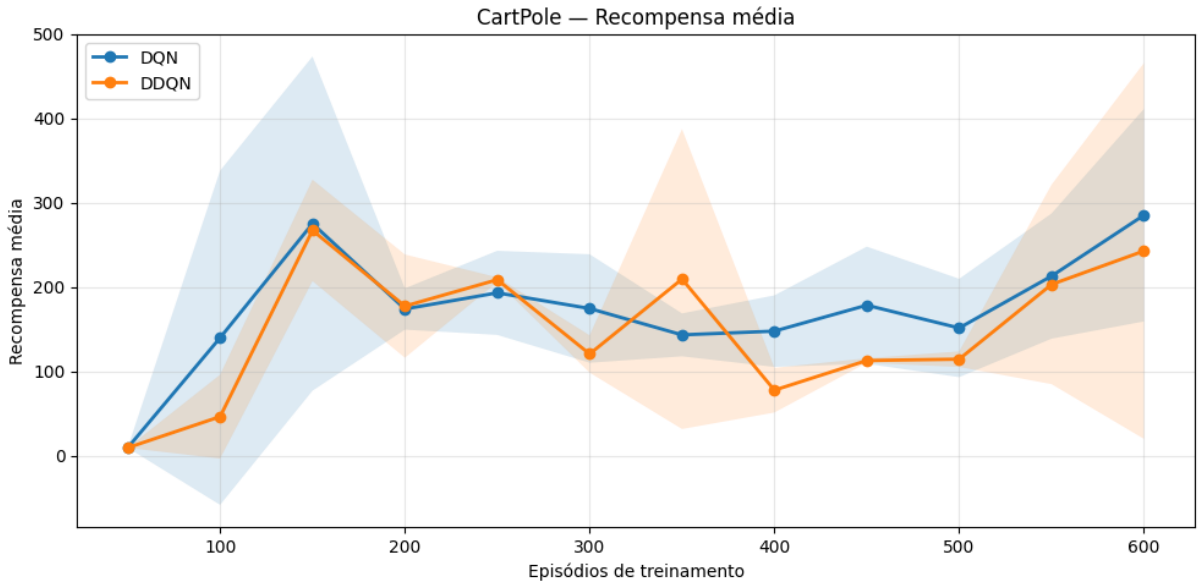


Figura 22: Recompensa média nas avaliações periódicas de DQN e DDQN na configuração B, com decaimento de exploração em 15.000 interações.

As curvas de treinamento (Figuras 23 e 24) mostram retornos maiores em B. Como há exploração, esses retornos não equivalem ao desempenho guloso.

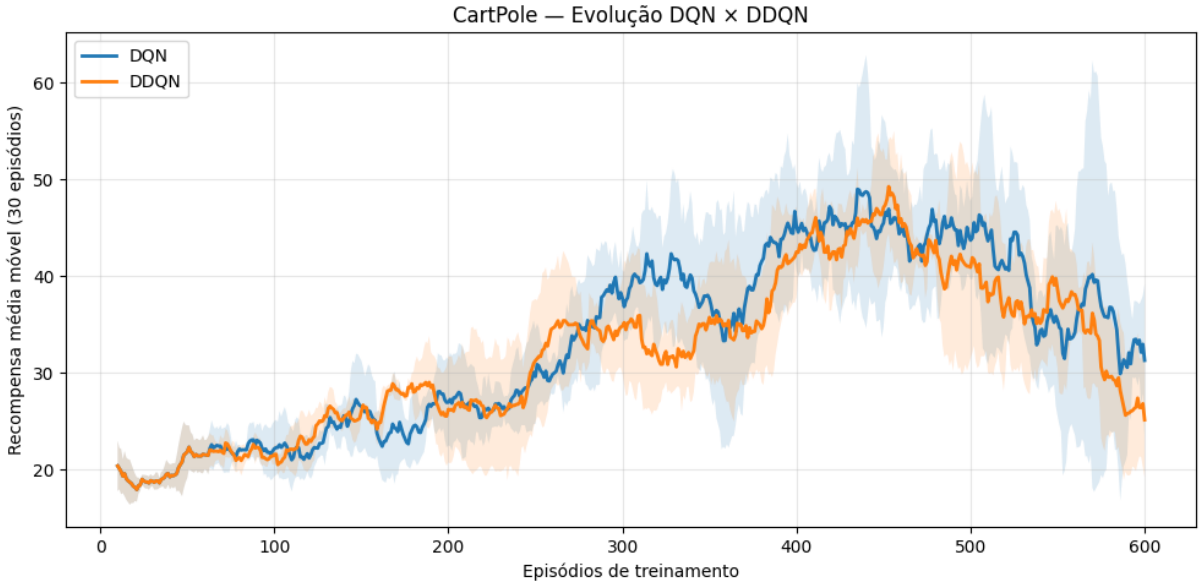


Figura 23: Recompensa média móvel de 30 episódios durante o treinamento na configuração A, com faixa de desvio-padrão entre sementes.

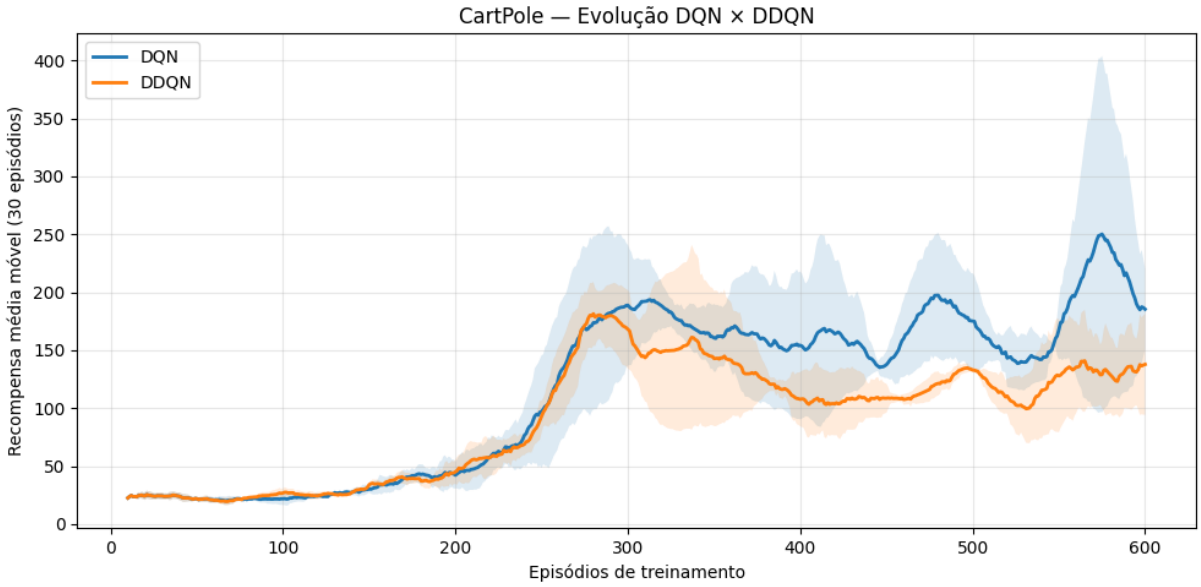


Figura 24: Recompensa média móvel de 30 episódios durante o treinamento na configuração B.

4.6.4 Efeito do cronograma de exploração

Na configuração A, ε terminou entre aproximadamente 0,44 e 0,50; em B, chegou a 0,05. Essa diferença influencia retornos de treinamento, mas não explica isoladamente instabilidades na avaliação.

Embora o orçamento fosse de 600 episódios, as interações diferiram entre políticas: em B, o DQN registrou 75.248, 74.826 e 61.177 passos, contra 59.257, 53.221 e 54.407 no DDQN (sementes 11, 22 e 33).

4.7. Resultados: DQN e DDQN no MountainCar-v0

4.7.1 Desempenho das demonstrações e resultados finais

As 80 demonstrações atingiram a meta em média após 119,56 passos, gerando 9.565 transições. São dados auxiliares, não evidência isolada de aprendizado neural.

A Tabela 22 reúne 100 partidas gulosas finais por semente, sem auxílio demonstrativo na avaliação.

Tabela 22: Avaliação final de DQN e DDQN com demonstrações no MountainCar-v0, por semente.

Algoritmo	Semente	Retorno médio	Sucesso (%)	Passos ao objetivo
DQN	11	−107,55	100	107,550
DQN	22	−107,68	100	107,680
DQN	33	−111,12	100	111,120
DDQN	11	−104,94	100	104,940
DDQN	22	−111,13	100	111,130
DDQN	33	−114,39	96	110,823

O DQN concluiu todas as 300 partidas; o DDQN concluiu 296, com quatro falhas na semente 33. O melhor retorno individual foi do DDQN na semente 11 (−104,94).

Tabela 23: Resumo da avaliação final no MountainCar-v0: médias e desvios-padrão entre três sementes.

Indicador	**DQN**	**DDQN**
Recompensa média	−108,783	−110,153
Desvio-padrão do retorno	2,025	4,800
Sucesso médio (%)	100,000	98,667
Desvio-padrão do sucesso (p.p.)	0,000	2,309
Posição máxima média	0,520	0,505
Passos médios em episódios bem-sucedidos	108,783	108,964

A vantagem agregada do DQN foi de 1,370 ponto. No DDQN, a recompensa média inclui partidas malsucedidas (−200), enquanto a duração média considera apenas chegadas à meta.

4.7.2 Evolução das avaliações e do treinamento

As curvas das avaliações (Figuras 25 e 26) mostram melhora gradual, oscilações intermediárias e sucesso próximo de 100% em várias execuções.

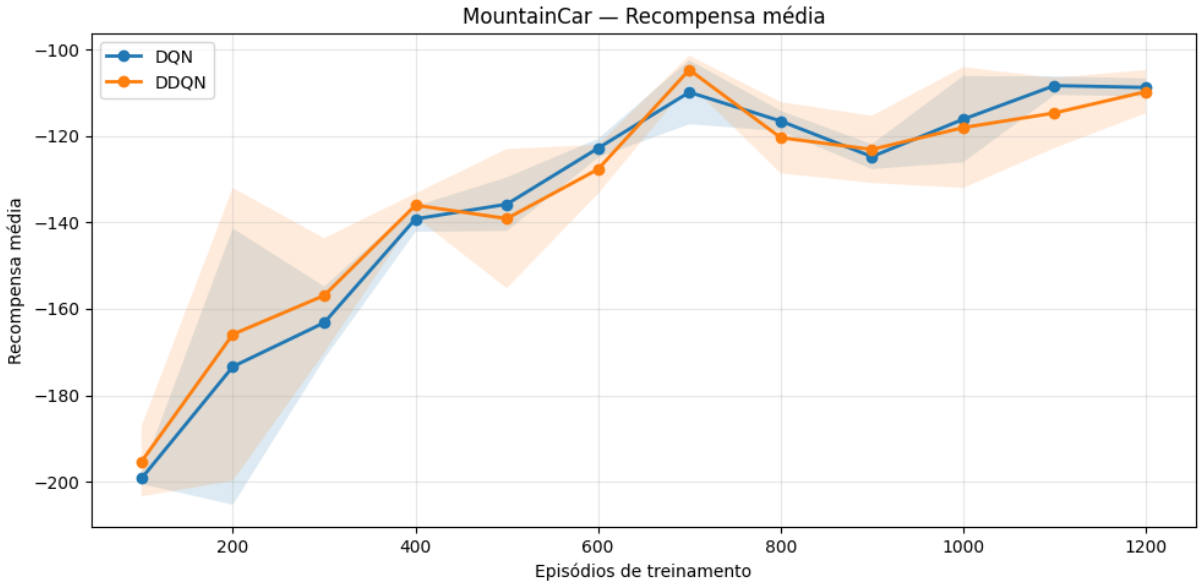


Figura 25: Recompensa média durante as avaliações periódicas de DQN e DDQN no MountainCar-v0 com experiências demonstrativas. Linhas: médias entre sementes; faixas: um desvio-padrão.

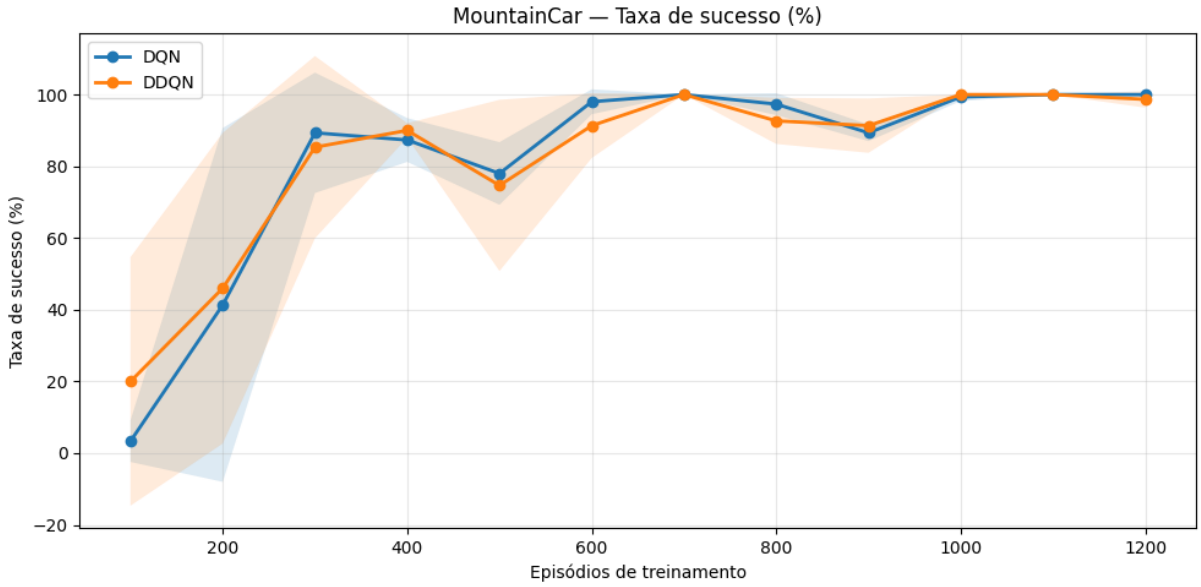


Figura 26: Evolução da taxa de sucesso nas avaliações periódicas das políticas DQN e DDQN treinadas com demonstrações.

A posição máxima média (Figura 27) complementa a taxa de sucesso; valores médios inferiores a $x = 0{,}5$ indicam que nem todas as partidas chegaram à meta.

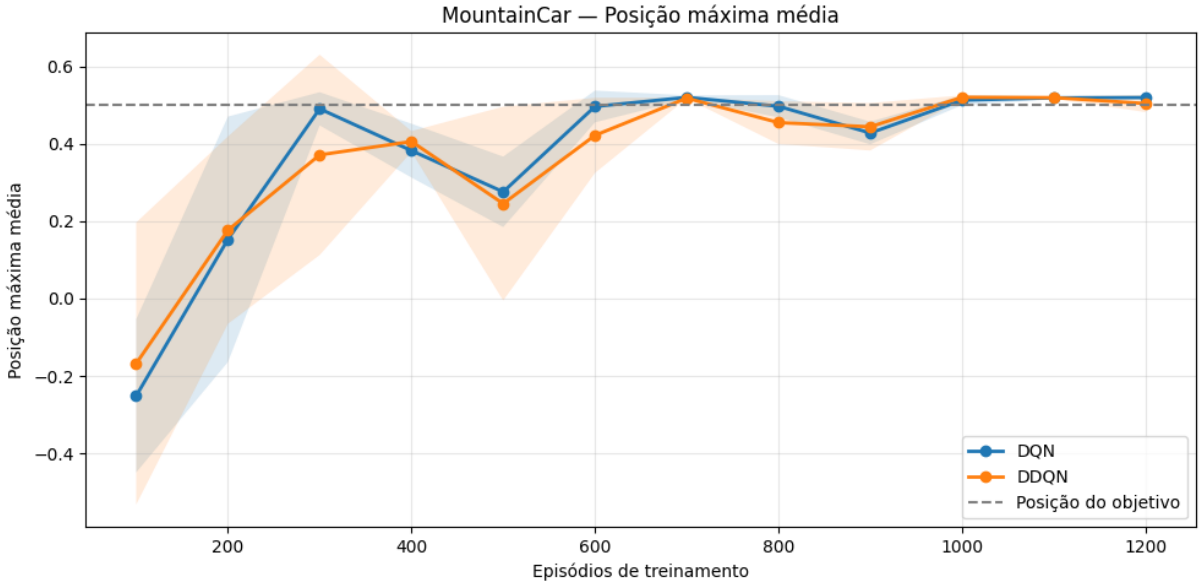


Figura 27: Posição máxima média alcançada nas avaliações de DQN e DDQN. A linha horizontal indica a posição $x = 0{,}5$ do objetivo.

A Figura 28 apresenta o retorno médio móvel sob exploração, não diretamente comparável às avaliações gulosas.

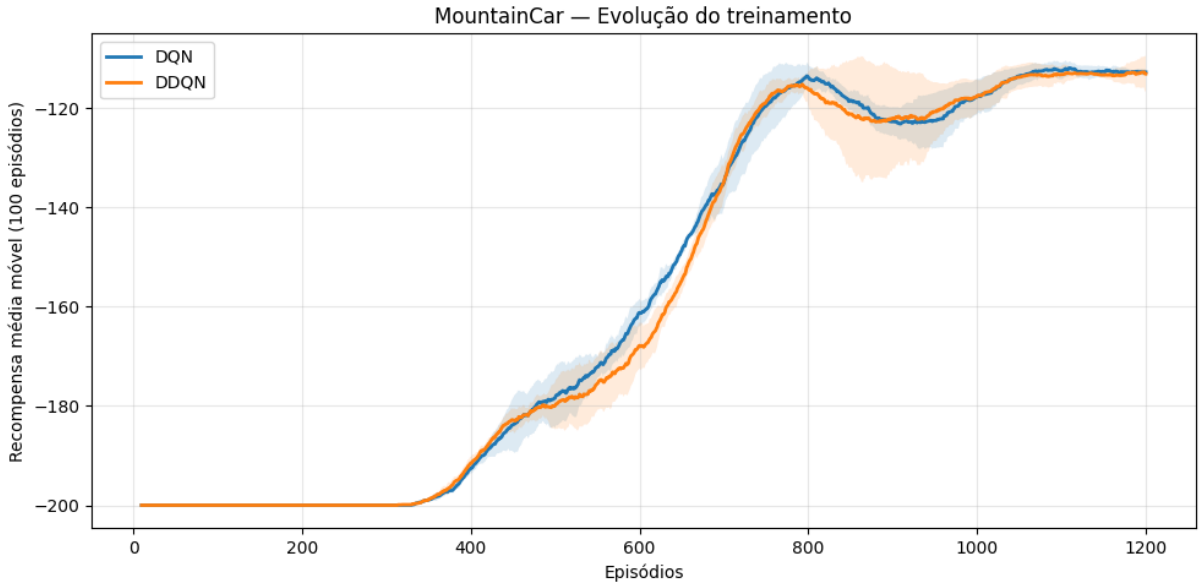


Figura 28: Evolução da recompensa durante o treinamento de DQN e DDQN com demonstrações no MountainCar-v0. Médias móveis de 100 episódios agregadas entre sementes.

4.8. Resultados: Space Invaders-v5

A Tabela 24 apresenta as métricas das políticas finais e da referência aleatória. O DDQN obteve pontuação média de 444,17, contra 381,67 do DQN, diferença descritiva de 62,50 pontos (16,4% em relação ao DQN). Ambos superaram a média da política aleatória, de 151,50 pontos, avaliada em 20 partidas (contra 30 por agente treinado). O DQN registrou a maior pontuação individual (800 pontos).

Tabela 24: Avaliação final no Space Invaders-v5: pontuação bruta por partida.

Indicador	**Aleatório**	**DQN**	**DDQN**
Partidas de avaliação	20	30	30
Pontuação média	151,50	381,67	444,17
Pontuação mediana	135,00	335,00	475,00
Desvio-padrão entre partidas	121,06	159,53	148,30
Pontuação máxima	640	800	745
Decisões médias por partida	492,10	646,63	677,03

Nas avaliações periódicas, a pontuação do DQN passou de 170,5 para 387,5 pontos e a do DDQN, de 99,5 para 401,0, entre 100 mil e um milhão de decisões. Os máximos periódicos foram 445,0 e 412,0 aos 800 mil passos, respectivamente. As Figuras 29 e 30 mostram o ganho geral e as oscilações ao longo do treinamento.

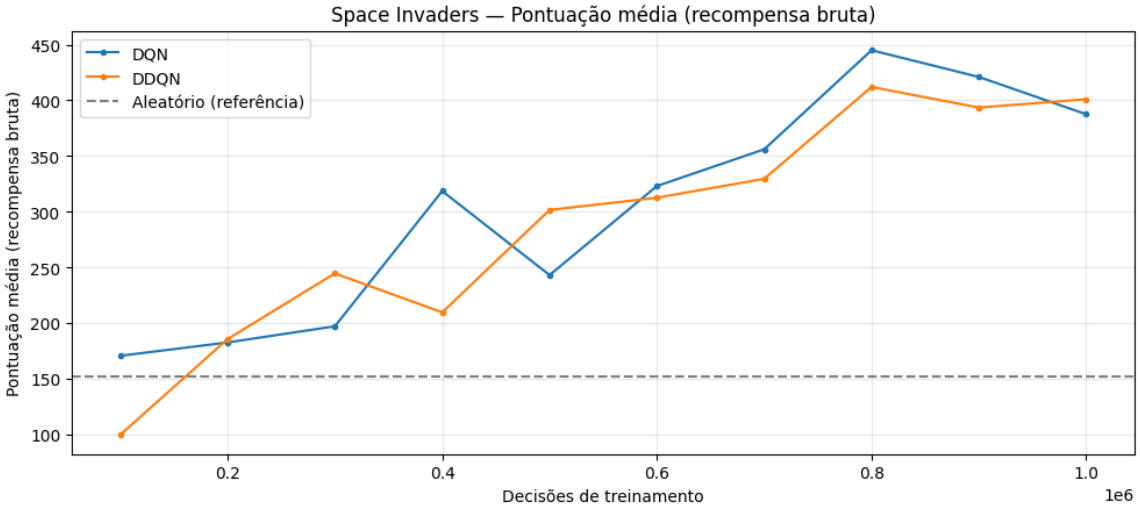


Figura 29: Pontuação média nas avaliações gulosas a cada 100.000 decisões, com dez partidas por avaliação, e referência aleatória.

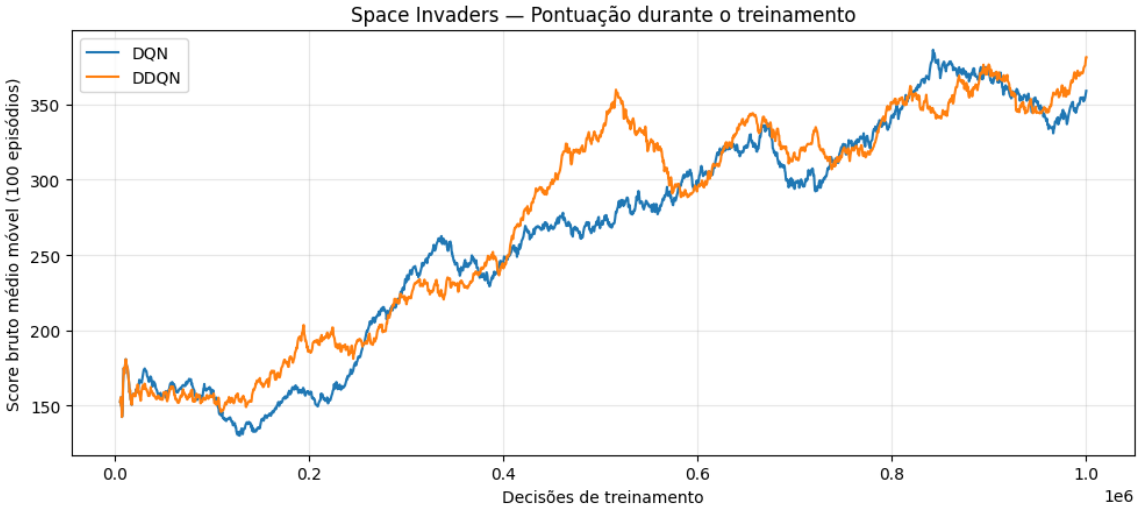


Figura 30: Pontuação bruta durante o treinamento de DQN e DDQN, suavizada por média móvel de 100 episódios.

4.9. Resultados: Pong-v5

A Tabela 25 apresenta os resultados finais dos modelos treinados por 2.000.000 de decisões. O DQN obteve recompensa média de +12,100 e venceu 28 das 30 partidas (93,33%), enquanto o DDQN apresentou recompensa média de −2,133 e venceu nove partidas (30,00%). A diferença descritiva foi de 14,233 pontos na recompensa média e 63,33 pontos percentuais na taxa de vitórias, favoráveis ao DQN nesta execução.

As Figuras 31 e 32 mostram a evolução nas avaliações periódicas de dez partidas. O DQN passou a registrar vitórias por volta de 800.000 decisões e alcançou taxas de 90% a 100% em diversas avaliações posteriores, embora tenha sofrido uma queda acentuada em torno de 1.400.000 decisões. O DDQN marcou progressivamente mais pontos, mas registrou vitórias apenas nas avaliações de 1.900.000 e 2.000.000 de decisões. A melhor

Tabela 25: Resultados finais de DQN e DDQN no Pong-v5: 30 partidas gulosas por algoritmo.

Indicador	**DQN**	**DDQN**
Decisões de treinamento	2.000.000	2.000.000
Episódios completos no treinamento	1.158	1.283
Recompensa média final	+12,100	−2,133
Pontos marcados médios	20,933	17,767
Pontos sofridos médios	8,833	19,900
Vitórias (partidas)	28/30	9/30
Taxa de vitórias (%)	93,333	30,000
Decisões médias por partida	2.138,833	2.595,833
Truncamentos (%)	0,000	0,000

recompensa média periódica foi de +11,5 para o DQN (1.500.000 decisões) e −1,2 para o DDQN (1.900.000 decisões). Esses valores, calculados com dez partidas fixas, não devem ser confundidos com as médias finais de 30 partidas.

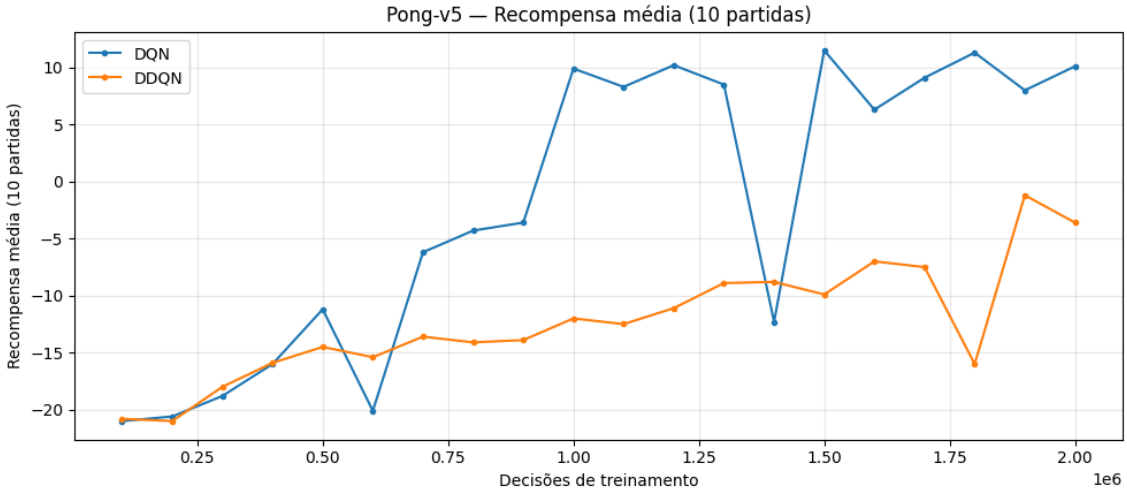


Figura 31: Recompensa média de DQN e DDQN nas avaliações periódicas do Pong-v5, com dez partidas gulosas a cada 100.000 decisões de treinamento.

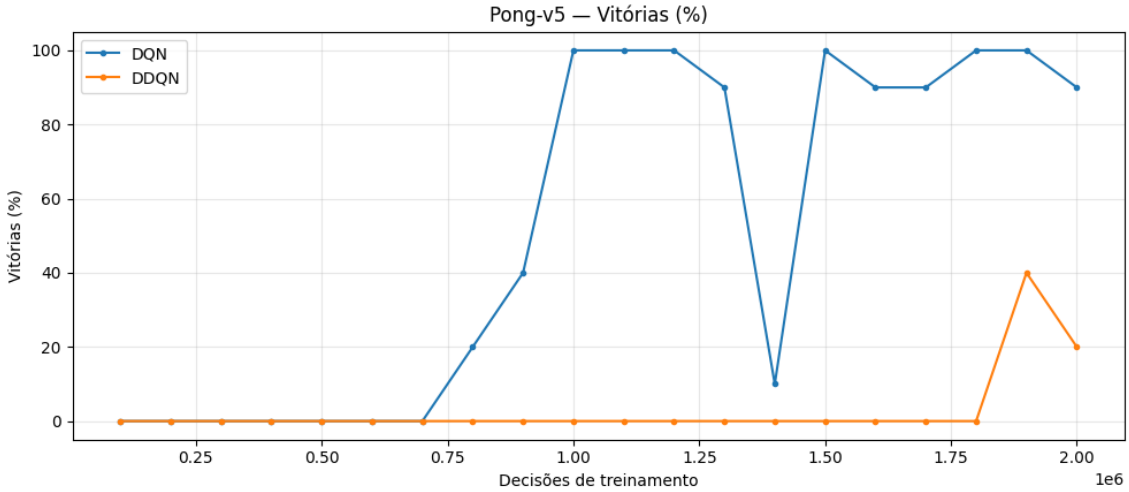


Figura 32: Taxa de vitórias nas avaliações periódicas dos agentes DQN e DDQN no Pong-v5, calculada em dez partidas por avaliação.

5. Discussão

5.1. Discussão: FrozenLake-v1

No FrozenLake, ambos chegaram a 100% de sucesso final, mas o Q-Learning apresentou avaliações periódicas mais regulares, enquanto o SARSA oscilou apesar dos 95% de sucesso nos últimos 100 episódios da rodada prolongada. Treinamento exploratório e avaliação gulosa, portanto, não medem exatamente o mesmo comportamento.

A distinção *on-policy*/*off-policy* pode contribuir para essas diferenças, mas não as demonstra causalmente. $\alpha = 0{,}5$ constante e desempates aleatórios também podem favorecer oscilações.

Como o decaimento de ε dependia do total de episódios, não se isolou o efeito do treinamento prolongado. Houve apenas uma execução por configuração, em mapa determinístico; recomendam-se mais sementes e testes com `is_slippery=True`.

5.2. Discussão: Blackjack-v1

No Blackjack, os dois algoritmos superaram a política aleatória em cerca de 14,3 pontos percentuais de vitórias, mas as diferenças finais entre SARSA e Q-Learning ficaram abaixo da variação entre sementes, sem evidência de superioridade estatística.

As políticas da semente 11 diferiram localmente. Retornos médios negativos são compatíveis com aprendizado nesse jogo estocástico. Três sementes, referências sem repetições independentes e α constante limitam a interpretação; mais partidas e análise de estados visitados seriam úteis.

5.3. Discussão: CliffWalking-v1

No CliffWalking, o Q-Learning produziu rotas gulosas mínimas de 13 passos, mas expostas a quedas quando se manteve a exploração. O SARSA utilizou trajetórias bem-sucedidas mais longas (17 passos) e sofreu menos quedas, comportamento compatível com seu alvo

on-policy.

Menor risco não significou sucesso guloso em todas as sementes: o SARSA apresentou ciclos sem alcançar o objetivo. A exploração ocasional pode romper esses ciclos, explicando a diferença entre políticas gulosas e exploratórias. Mais episódios melhoraram métricas médias exploratórias sem eliminar a falha de uma das sementes.

Os resultados dependem de $\alpha = 0{,}5$, $\varepsilon = 0{,}1$, três sementes e 200 passos por episódio; não demonstram convergência geral.

5.4. Discussão: Taxi-v4

No Taxi, ambas as políticas finalizaram com 100% de entregas e retorno médio +7,949, mas Q-Learning atingiu primeiro 100% nas avaliações: 4.000 episódios, ante 16.000 do SARSA. Os marcos correspondem à frequência de avaliação, não ao instante exato de aprendizado.

O contraste *off-policy*/*on-policy* é compatível com a diferença inicial, mas não a explica isoladamente. Médias finais idênticas não implicam tabelas iguais; sem máscaras, chuva e mudanças de destino, e com três sementes, não há garantia de optimalidade geral.

5.5. Discussão: CartPole-v1

No CartPole tabular, ambas as discretizações superaram o agente aleatório e a resolução B elevou a média, mas não uniformemente: a semente 11 do Q-Learning piorou.

O SARSA atingiu 500 pontos nas 600 avaliações finais de B, resultado limitado pelo teto do ambiente, não prova de convergência. As oscilações e α constante impedem atribuir os ganhos exclusivamente à distinção entre algoritmos.

Mais sementes, outras resoluções e perturbações iniciais ampliariam a análise. A comparação com DQN/DDQN permanece descritiva devido aos diferentes orçamentos e representações.

5.6. Discussão: DQN e DDQN no CartPole-v1

No CartPole profundo, a configuração B elevou as médias finais, mas não eliminou grande variabilidade: o DDQN B obteve 500 pontos na semente 11 e 124,01/103,66 nas outras, sem superioridade uniforme de nenhum método.

Picos intermediários não se mantiveram, como no DDQN A da semente 22 e no DDQN B da semente 33. O decaimento mais curto reduziu ε ao mínimo em B, sem garantir estabilidade das avaliações gulosas.

O viés de superestimação, motivação do DDQN, não foi medido; recompensa inferior não refuta seu efeito. O orçamento de 600 episódios também gerou números distintos de interações. Futuras análises devem equalizar decisões, ampliar sementes e medir estimativas Q em avaliações independentes.

5.7. Discussão: DQN e DDQN no MountainCar-v0

No MountainCar, as tentativas iniciais sem orientação falharam, mas não constituíram controle equivalente. As 9.565 transições demonstrativas integraram 25% dos minibatches; assim, os resultados não representam exploração autônoma desde o início.

O DQN teve 300/300 sucessos e o DDQN 296/300, com retornos médios $-108{,}783$ e $-110{,}153$, diferença pequena entre três sementes. O DDQN 33 teve quatro falhas, reforçando a necessidade de separar retorno, sucesso e duração dos episódios concluídos.

Sem um controle com orçamento comparável, não é possível quantificar o ganho causado pelas demonstrações. Também não se isolou a influência da rede-alvo e do *replay buffer*; recomendam-se mais sementes e testes da proporção de demonstrações.

5.8. Discussão: DQN e DDQN no Space Invaders-v5

Os dois agentes apresentaram ganhos de pontuação ao longo do treinamento, indicando aprendizagem de comportamentos mais eficazes que a referência aleatória nas condições avaliadas. O DDQN encerrou o experimento com maior média e mediana, enquanto o DQN alcançou o maior resultado individual. A variabilidade entre partidas e as oscilações das avaliações periódicas demonstram que o desempenho não evoluiu de modo uniforme.

A melhor avaliação periódica e a avaliação final empregaram diferentes conjuntos de partidas; portanto, suas pontuações não constituem medidas diretamente equivalentes. Além disso, os desvios-padrão da Tabela 24 descrevem a dispersão entre partidas, não entre treinamentos independentes. Como somente a semente 33 foi utilizada, os resultados não demonstram superioridade estatística do DDQN nem permitem avaliar a robustez entre inicializações. Investigações futuras podem repetir os treinamentos com outras sementes e diferentes orçamentos de decisões, mantendo as condições equivalentes entre os algoritmos.

5.9. Discussão: DQN e DDQN no Pong-v5

O treinamento com 2.000.000 de decisões por algoritmo apresentou aprendizagem expressiva no Pong-v5, especialmente no DQN, que obteve 93,33% de vitórias na avaliação final. O DDQN também melhorou em relação ao início, mas encerrou com 30,00% de vitórias e 17,767 pontos marcados por partida, abaixo do DQN nessa execução. As curvas evidenciaram instabilidade durante a aprendizagem, inclusive uma redução temporária do desempenho do DQN antes de sua recuperação.

A comparação manteve ambiente, arquitetura, orçamento e hiperparâmetros equivalentes, mas envolveu uma única semente, escolhida após experimentos preliminares. Portanto, a vantagem observada do DQN é descritiva e não demonstra superioridade estatística geral nem convergência dos agentes. Além disso, o viés de superestimação que motiva o DDQN não foi medido diretamente. Novas execuções com sementes independentes seriam necessárias para avaliar a robustez e a variabilidade dos resultados.

6. Conclusões

Os experimentos realizados no âmbito da disciplina de Aprendizado por Reforço do PPgTI/UFRN permitiram consolidar os conceitos teóricos por meio da implementação e avaliação dos algoritmos SARSA(0), Q-Learning(0), DQN e DDQN em diferentes ambientes da biblioteca Gymnasium. As atividades evidenciaram a influência das características dos ambientes, das estratégias de exploração e dos parâmetros de treinamento sobre o desempenho e a estabilidade das políticas aprendidas.

Nos ambientes discretos, SARSA(0) e Q-Learning(0) demonstraram capacidade de aprender políticas eficazes, embora com diferenças no processo de aprendizagem. No FrozenLake, ambos alcançaram 100% de sucesso na avaliação final, enquanto o Q-Learning apresentou maior regularidade nas avaliações periódicas. No Blackjack, os métodos obtiveram desempenhos próximos, superiores às estratégias de referência. O CliffWalking evidenciou o compromisso entre eficiência e exposição ao risco: o Q-Learning produziu trajetórias gulosas mais curtas, enquanto o SARSA apresentou menor frequência de quedas sob exploração. No Taxi, ambos alcançaram 100% de entregas concluídas, mas o Q-Learning atingiu esse desempenho com menor quantidade de episódios.

No CartPole, a discretização mais refinada favoreceu os resultados médios dos métodos tabulares, destacando-se o SARSA(0), que alcançou a recompensa máxima em todas as avaliações finais dessa configuração. Em contrapartida, os experimentos com DQN e DDQN apresentaram maior variabilidade entre sementes e oscilações de desempenho, demonstrando que o emprego de redes neurais não garante, isoladamente, políticas mais estáveis ou eficientes. No MountainCar, a incorporação de experiências demonstrativas permitiu obter elevadas taxas de sucesso com ambos os algoritmos profundos, ressaltando a importância das experiências disponíveis durante o treinamento.

No Space Invaders, DQN e DDQN apresentaram evolução nas pontuações e superaram a referência aleatória. O DDQN alcançou maior pontuação média na avaliação final, enquanto o DQN registrou a maior pontuação individual. Entretanto, a utilização de uma única semente de treinamento limita a generalização desses resultados e impede afirmar superioridade estatística entre os métodos.

No Pong, a rodada de treinamento com orçamento ampliado e espaço de três ações apresentou aprendizagem substancial, com o DQN alcançando 93,33% de vitórias e o DDQN, 30,00%, após 2.000.000 de decisões por algoritmo. A comparação com os pilotos anteriores sugere a relevância do orçamento e da configuração de ações, sem isolar causalmente a contribuição de cada alteração. Persistiram oscilações durante o treinamento. Embora o DQN tenha apresentado desempenho superior nessa execução, a utilização de uma única semente impede generalizações estatísticas sobre os métodos.

De modo geral, os resultados demonstram que não houve superioridade uniforme de um algoritmo em todos os ambientes investigados. O desempenho dependeu da representação dos estados, da estrutura das recompensas, da exploração, do orçamento de treinamento e da variabilidade entre execuções. Além disso, as diferenças metodológicas entre os experimentos, especialmente quanto ao número de interações e ao uso de demonstrações,

restringem comparações diretas entre ambientes e famílias de algoritmos.

Conclui-se que os experimentos cumpriram seu propósito didático ao relacionar os fundamentos do aprendizado por reforço aos desafios práticos de implementação, treinamento e avaliação de agentes inteligentes. A análise conjunta reforça a importância de procedimentos experimentais controlados e de múltiplas métricas para interpretar a aprendizagem, a estabilidade e as limitações das políticas obtidas.

Referências

BELLEMARE, M. G.; NADDAF, Y.; VENESS, J.; BOWLING, M. The Arcade Learning Environment: An Evaluation Platform for General Agents. **Journal of Artificial Intelligence Research**, v. 47, p. 253–279, 2013. Disponível em: `https://doi.org/10.1613/jair.3912`.

LIN, L.-J. Self-improving reactive agents based on reinforcement learning, planning and teaching. **Machine Learning**, v. 8, p. 293–321, 1992. Disponível em: `https://doi.org/10.1007/BF00992699`.

MNIH, V. et al. Human-level control through deep reinforcement learning. **Nature**, v. 518, p. 529–533, 2015. Disponível em: `https://doi.org/10.1038/nature14236`.

RUMMERY, G. A.; NIRANJAN, M. **On-line Q-learning using connectionist systems**. Cambridge: University of Cambridge, Department of Engineering, 1994. Technical Report CUED/F-INFENG/TR 166.

SUTTON, R. S. Learning to predict by the methods of temporal differences. **Machine Learning**, v. 3, p. 9–44, 1988. Disponível em: `https://doi.org/10.1007/BF00115009`.

SUTTON, R. S.; BARTO, A. G. **Reinforcement Learning: An Introduction**. 2. ed. Cambridge, MA: MIT Press, 2018.

TOWERS, M. et al. Gymnasium: A Standard Interface for Reinforcement Learning Environments. **arXiv**, arXiv:2407.17032, 2024. Disponível em: `https://arxiv.org/abs/2407.17032`.

VAN HASSELT, H. Double Q-learning. In: **Advances in Neural Information Processing Systems 23**. 2010. p. 2613–2621.

VAN HASSELT, H.; GUEZ, A.; SILVER, D. Deep Reinforcement Learning with Double Q-Learning. In: **Proceedings of the AAAI Conference on Artificial Intelligence**. v. 30, n. 1, p. 2094–2100, 2016. Disponível em: `https://doi.org/10.1609/aaai.v30i1.10295`.

WATKINS, C. J. C. H.; DAYAN, P. Q-learning. **Machine Learning**, v. 8, p. 279–292, 1992. Disponível em: `https://doi.org/10.1007/BF00992698`.